基于深度学习的中性粒细胞必需蛋白筛选与验证研究

（申请清华大学工学硕士学位论文）

培 养 单 位： 生物医药与健康工程研究院

学　　科： 生物医学工程

研　究　生： 唐　　健

指 导 教 师： 张 灿 阳　副教授

二〇二六年三月

基于深度学习的中性粒细胞必需蛋白筛选与验证研究

唐　健

Deep learning-based screening and validation of essential proteins in neutrophils

Thesis submitted to

Tsinghua University

in partial fulfillment of the requirement

for the degree of

Master of Science

in

Biomedical Engineering

by

Tang Jian

Thesis Supervisor: Associate Professor Zhang Can Yang

March, 2026

学位论文指导小组、公开评阅人和答辩委员会名单

指导小组名单

李 XX	教授	清华大学
王 XX	副教授	清华大学
张 XX	助理教授	清华大学

公开评阅人名单

刘 XX	教授	清华大学
陈 XX	副教授	XXXX 大学
杨 XX	研究员	中国 XXXX 科学院 XXXXXXX 研究所

答辩委员会名单

主席	赵 XX	教授	清华大学
委员	刘 XX	教授	清华大学
	杨 XX	研究员	中国 XXXX 科学院 XXXXXXX 研究所
	黄 XX	教授	XXXX 大学
	周 XX	副教授	XXXX 大学
秘书	吴 XX	助理研究员	清华大学

关于学位论文使用授权的说明

本人完全了解清华大学有关保留、使用学位论文的规定，即：

清华大学拥有在著作权法规定范围内学位论文的使用权，其中包括：（1）已获学位的研究生必须按学校规定提交学位论文，学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文；（2）为教学和科研目的，学校可以将公开的学位论文作为资料在图书馆、资料室等场所供校内师生阅读，或在校园网上供校内师生浏览部分内容；（3）按照上级教育主管部门督导、抽查等要求，报送相应的学位论文。

本人保证遵守上述规定。

作者签名：_____	导师签名：_____
日　　期：_____	日　　期：_____

摘　要

中性粒细胞在执行先天免疫功能时处于极端的物理化学应激环境，维持其功能稳态的关键分子往往具有显著的情境依赖性。由于该细胞属于难以进行高通量遗传操纵的终末分化细胞，传统筛选手段难以系统识别其在特定激活状态下的功能依赖蛋白。本研究利用蛋白语言模型构建了双层必需性评估体系，通过量化计算识别出以 ATP6V1B2 为代表的、在免疫相关依赖情境下具有高选择性的功能调控靶点。研究采用 ProtT5 预训练模型提取序列高维特征，并构建了基于单头注意力机制的判别架构，在独立测试集上实现了 AUROC 0.9272、AUPRC 0.8245 的预测性能。本研究通过 Human-level 与 Immune-level 的双层 PES 评分差异分析（ΔPES）识别情境特异必需蛋白。特征解析显示，此类蛋白呈现显著的正电荷偏移与疏水核心强化，与其在中性粒细胞酸性吞噬体及高氧化环境下的功能执行相一致。为证实模型预测结果的生物学可靠性，本研究引入溶酶体亮氨酸氨基肽酶 LyLAP (PLBD1) 作为功能验证基准。注意力图谱识别了其关键功能结构域及重要残基，结合既有文献对 LyLAP 维持溶酶体膜稳态的机制解析，支持了模型对免疫依赖信号的识别能力。在此基础上，本研究进一步分析了 ATP6V1B2 在活化中性粒细胞状态下的特异必需性。本文将该状态具体界定为急性炎症应答中以氧化爆发增强和颗粒/溶酶体功能负荷升高为特征的活化中性粒细胞状态，并在实验层面采用 PMA 刺激 HL-60 作为体外替代模型进行验证。ATP6V1B2 在 Immune-level 下的 PES 得分（0.952）远高于其人群进化层面的得分（0.007），提示其并非维持基础生存的核心基因，而更可能是上述活化状态下参与酸化动力学调控的重要节点。机制分析表明，ATP6V1B2 介导的 V-ATPase 快速装配可能是中性粒细胞应对氧化应激和溶酶体负荷升高的重要过程。本研究建立的预测与筛选框架，为发现具有高度细胞选择性的免疫调节靶点提供了新的技术路径。

关键词：中性粒细胞；ATP6V1B2 蛋白；深度学习；靶点筛选；情境必需性

Abstract

Neutrophils operate in extreme physicochemical environments during innate immune responses, where molecular mechanisms ensuring functional homeostasis are highly context-dependent. Due to their terminal differentiation and limited lifespan, conventional high-throughput methods struggle to identify essential proteins in specific activated states. This study introduces a dual-layer essentiality evaluation system based on Protein Language Models (PLMs), identifying ATP6V1B2 as a novel regulatory target with high selectivity in an immune-related dependency context.

Using the ProtT5 pre-trained model, high-dimensional sequence embeddings are generated and applied to a discriminant architecture optimized with Single-head Attention. The model achieves superior performance with an AUROC of 0.9272 and an AUPRC of 0.8245. The work compares Protein Essentiality Scores (PES) across two levels: human evolutionary constraint (Human-level) and immune-related dependency (Immune-level). Immune-specific essential proteins show shifts toward lower molecular weight, increased basicity, and reinforced hydrophobic cores, supporting stability in neutrophil phagosomes.

To validate the framework, lysosomal leucine aminopeptidase LyLAP (PLBD1) was used as a baseline. The model's predictions were confirmed by known mechanisms regarding LyLAP's role in lysosomal membrane integrity. In the validation stage, the biological state of interest was further specified as an activated neutrophil state characterized by enhanced oxidative burst and increased granule/lysosomal functional load, with PMA-stimulated HL-60 cells used as an in vitro surrogate. ATP6V1B2 was identified as a high-confidence target, exhibiting a much higher PES in the Immune-level context (0.952) compared to the human evolutionary level (0.007). This suggests ATP6V1B2 modulates neutrophil acidification dynamics, with rapid V-ATPase assembly playing a key regulatory role under oxidative and lysosomal stress. This framework offers a novel approach for discovering selective immunomodulatory targets.

Keywords: Neutrophils; ATP6V1B2; Deep Learning; Target Screening; Context-specific Essentiality

目 录

摘 要.....I
Abstract.....II
目 录.....III
附表清单.....V
符号和缩略语说明.....VI
第 1 章 引言.....1
1.1 研究背景与意义.....1
1.1.1 中性粒细胞的生物学功能及其在疾病中的作用.....1
1.1.2 蛋白质必需性理论与功能基因组学研究进展.....1
1.1.3 细胞类型与生理背景对蛋白质必需性的影响.....2
1.1.4 基于 PLM 的必需性预测方法及研究意义.....3
1.2 国内外研究现状.....4
1.2.1 传统蛋白质必需性鉴定方法及其局限性.....4
1.2.2 早期计算预测方法：网络与浅层序列特征驱动.....6
1.2.3 深度学习与 PLM 的兴起.....9
1.2.4 PIC 模型及其方法学框架.....12
1.3 问题的提出与研究设计.....13
1.3.1 研究问题与总体思路.....13
1.3.2 技术路线与论文结构安排.....14
第 2 章 模型的构建与优化.....16
2.1 数据来源与免疫相关标签体系构建.....16
2.1.1 人类遗传约束数据.....16
2.1.2 免疫细胞系必需性数据.....17
2.1.3 蛋白质序列获取与标准化处理.....19
2.2 模型架构设计.....20
2.2.1 序列嵌入模块：ProtT5 表示学习机制.....20
2.2.2 分类模块.....22
2.3 消融实验与模型优化.....24
2.3.1 模块消融实验.....24
2.3.2 Attention Head 数量消融实验.....26

2.4　模型训练与结果 27
2.4.1　数据流转与样本分布 27
2.4.2　训练环境与超参数设置 27
2.4.3　训练过程与结果分析 28
第 3 章　中性粒细胞候选必需蛋白筛选与特征分析 30
3.1　基于 PES 评分的蛋白功能分群 30
3.2　免疫特异必需蛋白的理化特征分析 32
3.3　结构域富集与功能机制建模 34
3.4　核心候选蛋白的注意力图谱解析与结构域功能验证 36
第 4 章　核心候选蛋白的机制解析与功能验证 39
4.1　免疫特异性候选蛋白的功能关联分析与筛选结果 39
4.2　LyLAP（PLBD1）的机制解析与模型验证意义 41
4.3　ATP6V1B2 的功能推断与验证路径 42
第 5 章　总结与展望 44
5.1　全文总结 44
5.1.1　主要研究工作与结果 44
5.1.2　创新点与研究意义 45
5.2　研究局限性分析 45
5.2.1　数据层面的局限 45
5.2.2　模型层面的局限 46
5.2.3　验证层面的局限 46
5.3　未来工作展望 46
5.3.1　推进多模态信息融合，提升情境分辨率 46
5.3.2　加强原代细胞验证，补齐因果证据链 46
5.3.3　面向转化应用开展靶点分层与干预设计 47
5.3.4　构建可复用的免疫细胞必需性研究范式 47
参考文献 48
致　谢 53
声　明 54
个人简历、在学期间完成的相关学术成果 55
指导教师评语 56
答辩委员会决议书 57

附表清单

表 2.1　不同结构增强策略在测试集上的性能比较 25
表 2.2　不同注意力 head 数的性能比较 26
表 2.3　数据流转与筛选损耗统计表 27
表 2.4　建模数据集类别分布统计 27
表 2.5　模型在独立测试集上的性能指标 29
表 4.1　免疫特异性必需评分前 10 的蛋白.....40

符号和缩略语说明

PLM	蛋白语言模型 (Protein Language Model)
PES	蛋白质必需性评分 (Protein Essentiality Score)
ΔPES	跨层级必需性评分差异
LOEUF	基因功能缺失观察值/期望值比例置信上界 (Loss-of-function Observed/Expected Upper bound Fraction)
gnomAD	人类基因组聚合数据库 (Genome Aggregation Database)
DepMap	癌症依赖图谱项目 (Cancer Dependency Map)
MLP	多层感知机 (Multilayer Perceptron)
CNN	卷积神经网络 (Convolutional Neural Network)
Attention	
ProtT5	基于 T5 架构的预训练蛋白语言模型
AUROC	样本特征曲线下面积 (Area Under the Receiver Operating Characteristic Curve)
AUPRC	精准率-召回率曲线下面积 (Area Under the Precision-Recall Curve)
V-ATPase	液泡型 ATP 酶 (Vacuolar-type ATPase)
LyLAP	溶酶体亮氨酸氨基肽酶 (Lysosomal Leucine Aminopeptidase)
PLBD1	磷脂酶 B 结构域包含蛋白 1 (Phospholipase B Domain-containing 1)
ATP6V1B2	V-ATPase V1 结构域 B2 亚基
NETs	中性粒细胞胞外诱捕网 (Neutrophil Extracellular Traps)
ROS	活性氧 (Reactive Oxygen Species)
PPI	蛋白质相互作用网络 (Protein-Protein Interaction)
MSA	多序列比对 (Multiple Sequence Alignment)
pI	等电点 (Isoelectric Point)
MW	分子量 (Molecular Weight)
aa	氨基酸 (Amino Acid)
ECM	细胞外基质 (Extracellular Matrix)
GO	基因本体论 (Gene Ontology)

第 1 章　引言

1.1　研究背景与意义

1.1.1　中性粒细胞的生物学功能及其在疾病中的作用

中性粒细胞（neutrophil）是外周血中数量最为丰富的白细胞亚群，占循环白细胞总数的 50%–70%[1]。在传统免疫学框架中，中性粒细胞被视为先天免疫防御的前线效应细胞，其主要通过趋化迁移、吞噬作用、颗粒酶释放以及 NADPH 氧化酶复合体介导的 ROS 爆发等机制清除入侵病原体，从而快速限制感染扩散[2]。然而，近年来随着单细胞转录组学、空间组学及体内成像技术的发展，中性粒细胞的功能认知已发生显著转变。越来越多的研究表明，其并非单一均质群体，而是在分化阶段、组织微环境及病理背景影响下呈现高度动态的功能状态多样性[3]。

在生理条件下，中性粒细胞除参与抗感染反应外，还在组织修复、血管稳态维持及 ECM 重塑过程中发挥调节作用。例如，其释放的基质金属蛋白酶和弹性蛋白酶可调控局部炎症微环境并影响血管生成过程[4]。在病理条件下，中性粒细胞与多种重大疾病的发生发展密切相关。特别是在心血管疾病中，NETs 被证实参与动脉粥样硬化进展及血栓形成，是无菌性炎症放大的关键分子事件之一[5]。此外，在肿瘤微环境和自身免疫疾病中，中性粒细胞亦表现出功能重编程现象，对疾病进程产生重要影响。

综上，中性粒细胞已从传统意义上的急性杀伤细胞，转变为连接感染防御、组织修复与慢性炎症调控的重要免疫枢纽。其功能执行依赖复杂分子网络的精细调控，这为探究其特异性分子依赖模式提供了理论基础。

1.1.2　蛋白质必需性理论与功能基因组学研究进展

蛋白质必需性（protein essentiality）是生命科学与系统生物学研究中的核心概念，通常指编码该蛋白的基因在特定生物体系中对生物体的生存、发育及关键生理功能维持具有不可替代性[6-7]。必需蛋白作为细胞功能网络中的关键分子节点，广泛参与基础代谢过程、能量稳态维持、信号转导调控及细胞周期控制等核心生命活动，其功能缺失往往导致细胞死亡、发育异常或个体功能障碍[8]。

在功能基因组学层面，蛋白质必需性通常通过基因扰动后细胞适应度（fitness）变化进行定量评估。随着 CRISPR-Cas9 技术的发展，研究者可构建包含大量 sgRNA 的混合文库，在细胞群体中进行竞争性生长筛选，通过测序分析 sgRNA 丰度变化来推断基因对细胞存活的贡献[9]。为提高筛选结果的可靠性，研究者发展了多种

统计分析与误差校正方法，例如用于 sgRNA 富集分析的 MAGeCK 算法[10]，以及用于校正拷贝数变异影响的 CERES 模型[11]。这些方法的建立使得在全基因组尺度上系统识别必需基因进而筛选必需蛋白成为可能。

根据功能重要性的广泛程度，必需蛋白可进一步划分为“核心必需（core essential）”与“情境特异必需（context-specific essential）”。核心必需蛋白在多种细胞类型中均对细胞存活与基本生命活动具有关键作用，反映其在维持普遍生理过程中的基础地位；而情境特异必需蛋白则仅在特定遗传背景、分化阶段或功能状态下发挥不可替代作用。这强调，蛋白质的重要性并非固定不变，而是受到细胞类型与生理状态的调控[12]。

从分子网络角度来看，情境特异必需蛋白往往参与某一特定细胞状态下被强化或激活的功能通路。例如，在高代谢负荷、强氧化应激或快速增殖条件下，某些蛋白可能成为维持细胞稳态的关键节点，而在其他状态下则并非决定性因素。因此，必需蛋白不仅体现生命活动的基本构成，还反映不同细胞在特定生理或病理环境中的功能侧重。

这为精准医学提供了重要理论基础。若某一细胞类型或病理状态必须依赖特定蛋白维持其异常或过度活跃的功能过程，则该蛋白可能成为具有选择性的干预靶点。相较于在多种组织中均发挥基础功能的核心必需蛋白，细胞类型或状态特异的必需蛋白更可能在实现治疗效果的同时降低系统性毒副作用[13]。因此，围绕情境特异必需蛋白构建分子干预策略，已成为药物研发与治疗优化的重要方向。

综上，蛋白质必需性的研究不仅有助于揭示生命系统的基本运行规律，也为筛选具有选择性优势的治疗靶点提供理论依据。然而，在免疫细胞体系中，特别是在执行高强度炎症与应激功能的中性粒细胞中，其特异性必需蛋白谱及关键调控分子仍有待系统阐明。

1.1.3　细胞类型与生理背景对蛋白质必需性的影响

尽管蛋白质必需性常用于描述某一基因对细胞存活的重要程度，但越来越多的研究表明，必需蛋白并非一个固定不变的分子集合，而是受到细胞类型、分化阶段及生理背景的显著影响。不同细胞由于发育来源、功能定位及代谢特征存在差异，其维持基本稳态所需的关键分子亦不完全相同。这一现象在多种人源细胞系的系统性功能研究中得到验证，不同细胞类型之间的必需基因组成存在明显差异[14-15]。

进一步的分析显示，基因的重要性不仅取决于细胞类型本身，还受到功能状态与外界环境的调控。例如，在营养限制、氧化应激增强或信号通路持续激活等条件下，部分分子在维持细胞稳态中的作用被显著强化，而在静息或低负荷条件

下则不再表现为关键节点[16]。这种由生理背景驱动的功能重要性变化，说明蛋白质必需性具有明确的背景依赖特征。

此外，细胞分化与功能重编程亦会改变分子需求结构。单细胞层面的功能研究指出，不同分化阶段或功能亚群之间在关键调控分子的使用上存在显著差异[17-18]。在免疫系统中，细胞活化与效应功能执行往往伴随代谢重塑与信号网络重构，从而改变特定分子的功能地位[19]。因此，必需蛋白的界定需要结合具体细胞功能状态进行分析，而不能简单应用到其他细胞体系。

对于中性粒细胞而言，这种细胞类型与功能状态相关的必需性差异尤为突出。中性粒细胞在执行吞噬作用、ROS 爆发及 NETs 形成等功能时，处于高度代谢与氧化压力环境，其生存与功能维持依赖特定分子通路的精细调控。然而，目前公开的大规模必需基因数据主要来源于肿瘤细胞系，对终末分化且功能高度特化的免疫细胞覆盖相对有限。因此，在中性粒细胞这一特定细胞类型中系统识别并解析其特异性必需蛋白，对于理解其在炎症与免疫反应中的调控机制具有重要科学意义。

综上所述，蛋白质必需性呈现出显著的细胞类型特异性和生理背景依赖性。这一特征为针对特定细胞类型开展必需蛋白系统研究提供了理论基础，也为后续构建中性粒细胞特异必需蛋白预测框架奠定了生物学前提。

1.1.4　基于 PLM 的必需性预测方法及研究意义

在特定细胞类型中系统识别必需蛋白，往往面临现实实验条件的限制。以中性粒细胞为例，该类细胞属于终末分化细胞，寿命较短，体外培养时间有限，难以开展长期适应度评估实验。同时，成熟中性粒细胞体外扩增能力较弱，基因编辑效率较低，使得大规模功能筛选在技术上具有较高难度。此外，中性粒细胞在执行吞噬、ROS 爆发及 NETs 形成等功能时呈现高度动态变化，也增加了实验定量分析的复杂性。因此，仅依赖实验手段难以全面解析中性粒细胞特异性必需蛋白谱。

在此背景下，计算方法成为拓展必需蛋白研究的重要补充途径。早期研究表明，PPI 网络中的拓扑位置与基因重要性存在关联[8]，基于网络结构与表达特征的建模方法在一定程度上提高了预测效率。然而，这类方法通常依赖人工特征构建，对数据完整性与网络质量要求较高，在跨细胞类型场景中的泛化能力有限。

近年来，随着深度学习与自监督学习技术的发展，PLM 为从氨基酸序列中直接提取功能表征提供了新的技术路径。大规模自监督训练表明，模型能够从海量序列中学习到反映结构与进化约束的隐含表示[20]。进一步的研究显示，扩展模型规模与训练数据后，其内部表示可用于结构预测与功能推断等多种下游任务[21]。这种序列驱动的表征方式在实验数据受限的情况下具有重要潜力。

因此，在实验筛选存在客观限制的前提下，引入基于 PLM 的计算预测方法，

为在特定细胞类型背景下识别潜在关键靶点蛋白提供了可行路径。本研究正是在这一方法学背景下，构建面向中性粒细胞的必需蛋白预测框架。

1.2　国内外研究现状

1.2.1　传统蛋白质必需性鉴定方法及其局限性

蛋白质必需性的界定起源于经典遗传学研究，其核心逻辑是通过基因功能缺失所导致的生存或发育障碍来推断关键分子集合。早期在酿酒酵母中的系统性单基因缺失研究首次构建了全基因组尺度的必需基因图谱[22]，并进一步揭示必需基因在 PPI 网络中往往处于拓扑中心位置。此类研究奠定了“中心性—必需性”之间的统计关联框架，也推动了功能基因组学向系统层面发展。此外，最小基因组研究从系统生物学角度进一步强化了“核心生命功能集合”的概念。Hutchison 等通过转座子插入突变系统分析支原体基因组，提出最小生存基因集合（minimal gene set）的框架，强调维持细胞基本生命活动所需的核心基因模块[23]。随后，通过人工合成最小细胞基因组的研究进一步验证，在严格控制的培养条件下，可以通过去除非必需基因构建可稳定存活的简化基因组体系[24]。这些研究从理论层面巩固了“核心必需基因”作为维持生命基本结构与功能的稳定模块这一认识，并推动了将必需性视为相对稳定生物学属性的研究范式。然而，这些研究通常基于稳定遗传背景与标准培养条件，其所得结论隐含“基因功能重要性具有跨条件稳定性”的假设。

随着研究体系从模式生物拓展至哺乳动物细胞，RNA 干扰（RNA interference, RNAi）技术为大规模功能筛选提供了可行路径[25]。RNAi 通过抑制 mRNA 表达实现功能削弱，在多种细胞模型中用于识别存活相关基因。然而，大量研究指出 RNAi 存在脱靶效应与非特异性毒性问题[26]，且不同 siRNA 的敲降效率差异较大，使结果在不同实验平台间难以直接比较。进一步的系统评估显示，不同 RNAi 文库之间的筛选结果重叠度显著低于理论预期，提示技术噪声与脱靶效应对必需基因判定具有实质影响[27-28]。然而，相较于技术层面的偏差，更为关键的是 RNAi 筛选所依赖的“细胞适应度下降”判定框架。在多数研究中，基因必需性被等同于敲降后细胞增殖能力或存活率的显著下降[13]。这种定义方式在高度增殖的肿瘤细胞系中具有可操作性，但其本质反映的是特定培养条件下的生长依赖性，而非广义生理环境中的功能必需性。因此，RNAi 阶段所构建的必需基因集合在跨细胞类型、跨功能状态的推广过程中，天然受到“增殖依赖范式”的结构性限制。此外，RNAi 并非完全失活策略，其对低表达或功能冗余基因的干扰效果有限，从而可能低估某些分子的真实功能重要性。这些技术特征使得 RNAi 所构建的必需基因集

合在精度与可重复性方面受到质疑。

CRISPR-Cas9 技术的出现显著提升了基因组编辑的精确性与通量，使得在细胞层面开展全基因组尺度的功能筛选成为现实。基于混合 sgRNA 文库的竞争性筛选策略能够通过高通量测序定量分析扰动后 sgRNA 的丰度变化，从而推断基因对细胞适应度的贡献。后续研究通过改进 sgRNA 设计原则[29]与统计建模方法，进一步提高了筛选数据的可靠性与特异性。大规模项目（如 DepMap）构建了跨数百细胞系的基因依赖图谱，为系统解析肿瘤细胞的功能脆弱性提供了资源基础。除单基因必需性之外，近年来研究进一步揭示了基因功能在网络层面的复杂性。值得注意的是，随着大规模 CRISPR 数据的积累，对筛选结果的再分析逐渐揭示必需基因集合在不同细胞类型之间的显著差异。系统比较 300 余种癌细胞系的依赖图谱发现，仅有少数基因在多数细胞系中表现为“核心必需”，而大量基因呈现明显的细胞类型特异性依赖[30]。进一步的统计模型分析提出，应区分“核心必需基因”与“情境特异必需基因”，后者的必需性往往取决于特定代谢状态、信号通路激活情况或基因组背景[31]。

尽管如此，CRISPR 筛选体系仍依赖若干关键前提：其一，细胞能够稳定培养并维持足够时间以观察适应度差异；其二，基因组结构相对稳定，以避免拷贝数变异对切割信号的干扰；其三，细胞群体间竞争模型能够准确反映单基因扰动对生长优势的影响。然而，在非增殖型或终末分化细胞中，上述前提往往难以满足。以免疫细胞为例，原代 T 细胞或巨噬细胞的基因编辑效率与体外维持时间均显著低于肿瘤细胞系[32]。与可持续增殖的肿瘤细胞系不同，原代中性粒细胞属于终末分化细胞，生命周期短、转染效率低且对基因编辑高度敏感，使得大规模 CRISPR 筛选在该细胞类型中难以实施。即便在诱导分化模型中，编辑效率与筛选窗口期仍存在显著限制。因此，在中性粒细胞这一高度动态、应激响应依赖型的免疫细胞中，传统功能基因筛选技术难以构建完整的必需性图谱。现有研究多通过祖细胞分化模型或 HL-60 等替代细胞体系进行间接推断[33]。这种基于细胞系分化模型的间接推断，实质上是一种牺牲“生物学保真度”以换取“遗传可操作性”的折衷方案。HL-60 等替代体系在诱导分化后，其表观遗传景观、蛋白质水解酶组分以及颗粒蛋白的成熟度，均与外周血原代中性粒细胞存在显著的生化差异[34]。这意味着，在替代体系中鉴定出的“必需蛋白”，往往无法真实还原原代细胞在炎症反应中的功能依赖路径。如何在不破坏细胞稳态的前提下，直接在具备完全生物学活性的原代终末分化细胞中，构建高通量的蛋白质功能扰动与因果验证平台，是当前功能基因组学亟待跨越的边界。

综上所述，传统实验方法在因果验证与机制解析方面具有不可替代的优势，但

其可扩展性与跨细胞类型泛化能力受到实验体系与生物学条件的双重限制。尤其在功能高度动态、状态快速变化的免疫细胞系统中，如何构建既具备生物学真实性又具有跨背景可迁移性的必需蛋白识别框架，仍是当前领域亟待解决的问题。所以基于蛋白序列信息构建的深度学习预测框架不仅是实验方法的补充工具，更成为突破实验可行性边界的关键技术路径。通过对大规模序列语义空间的系统建模，可在无需直接基因扰动的前提下，从全基因组层面推断潜在功能依赖模式，为原代免疫细胞中的关键调控蛋白筛选提供理论依据。

1.2.2　早期计算预测方法：网络与浅层序列特征驱动

在深度表示学习方法引入之前，必需蛋白的计算预测主要依赖两类范式：一类以 PPI 网络（protein–protein interaction, PPI）拓扑特征为核心，另一类以蛋白序列及功能注释特征为输入构建传统机器学习分类器。二者分别从系统结构与分子属性层面建模蛋白重要性，其方法学演进过程构成了必需蛋白预测早期阶段的主要技术框架。

网络驱动预测方法的理论基础来源于 Jeong 等发表于 Nature 的研究[8]。该研究基于酿酒酵母的 PPI 网络数据，将节点度（degree centrality）与基因敲除实验获得的必需基因集合进行统计关联分析，发现高度连接节点中必需基因比例显著升高。作者据此提出“中心性-致死性规则”（centrality-lethality rule），为后续将网络拓扑指标纳入预测模型提供理论依据。随后 Hahn 与 Kern[35]在酵母线虫与果蝇三个真核物种中构建跨物种比较框架，对度中心性、介数中心性与紧密中心性等拓扑指标进行了系统统计分析。结果表明，多种中心性指标在不同物种中均与基因必需性显著相关，且关联方向一致。这一研究在跨物种层面强化了“网络位置约束功能重要性”的理论框架，使中心性从单一统计相关上升为具有潜在机制含义的结构特征。

然而，He 与 Zhang[36]的研究对“中心性-致死性规则”提出了反驳。他们指出，枢纽蛋白更可能为必需蛋白，并不必然源于其在维持网络整体结构中的关键作用，而可能仅仅由于其参与的相互作用数量更多，从而更高概率地涉及“必需相互作用”（essential PPIs）。在其构建的概率模型中，蛋白必需性的发生可由简单的组合概率解释，而无需引入网络拓扑结构的全局性质。进一步分析表明，在控制度中心性后，介数中心性与紧密中心性等全局中心性指标不再表现出额外解释力。这表明 PPI 网络本质上是静态、汇总式的结构图谱，其边的存在并不区分相互作用的条件依赖性、特异性或调控状态。在此框架下，将必需性视为网络拓扑位置的函数，实质上忽略了蛋白功能的动态调控本质。换言之，中心性指标所捕捉的更多是“连接频度”的统计特征，而非蛋白在特定生理或应激情境下的功能依赖机制。

在拓扑特征改进方面，研究人员对网络模块结构与必需基因分布进行了再分析，指出必需基因更倾向于位于高保守功能模块内部[37]。其方法通过识别网络模块并计算模块内部基因必需性富集程度，说明局部网络结构信息可能比全局度指标更具解释力。该工作推动预测特征从“单节点中心性”向“模块化组织特征”扩展。然而，其分析仍基于静态整合网络，未考虑不同条件下模块活跃度变化。

关于网络静态性的局限的研究同样也有进展，研究人员整合表达数据与互作网络，发现不同生理条件下活跃的功能模块发生切换，提出互作网络具有动态模块化特征[38]。尽管该研究并非直接针对必需性预测，但其结果从系统层面表明：静态整合网络仅是多状态网络的平均表示。因此，基于静态拓扑构建的预测模型难以刻画细胞情境依赖的功能脆弱性。

在人类互作网络层面，Luck 等 [5] 构建的高置信度二元互作图谱（HuRI）系统评估了现有互作数据库的覆盖率与偏倚[39]。该研究通过统一实验平台获得约 50000 条二元互作数据，并指出不同实验体系之间存在显著差异。其方法学意义在于揭示当前 PPI 网络并非完整生物系统的精确表示，而是实验条件下的观测子集。这意味着，基于现有 PPI 网络构建的预测模型，其特征输入本身存在不确定性来源。

与网络拓扑方法并行发展的，是基于蛋白序列与功能注释的预测路径。该类方法的共同前提是：蛋白必需性能够通过若干可解释的统计特征或功能标签加以刻画。这一前提在早期数据规模有限、功能认知尚不完善的背景下具有合理性，但随着数据规模与问题复杂性的提升，其内在张力逐渐显现。

早期研究主要围绕氨基酸组成、二肽频率及理化性质参数展开。这类特征具有明确生物学含义，能够解释为“组成偏好”或“结构稳定性倾向”。然而，其表达能力受限于一阶统计结构。即便引入进化保守性等序列特征以增强表示维度[40]，本质上仍然是对局部替代概率的线性展开，而非对序列全局依赖结构的建模。以 PSSM 为代表的保守性表示在部分场景中确实有效，提示进化约束与必需性存在关联；但其局限同样明显：当同源信息不足或蛋白进化速率较快时，该类表示会快速退化。

在算法层面，研究者逐渐意识到类别不平衡与特征冗余对性能的影响，因而引入平衡随机森林与特征选择策略[41]。这些改进提升了模型稳定性，却并未改变表示本身的能力边界。性能提升来源于决策函数的优化，而非对蛋白表示方式的根本重构。

随后，信息论特征被纳入框架[42]。序列复杂度与信息熵被视为潜在区分信号。这一尝试体现出对“统计频率不足”的反思，但信息熵仍属于低阶统计量，无法表

达残基间非线性耦合，也无法反映三维结构约束。因此，其改进效果呈现明显的边际递减趋势。

功能注释的引入在一定程度上改变了问题结构。通过整合 GO 语义信息[43]，模型开始显式利用已有生物学知识。这种策略增强了可解释性，却带来了新的依赖：预测能力受限于注释完整性。注释本身是研究积累的结果，而非蛋白本体属性。对于未充分研究的蛋白或特定细胞类型中的情境依赖性必需性，该类方法难以提供有效预测。

从整体上看，这一阶段的方法演进呈现出“特征扩展—性能提升—边际收敛”的轨迹。其根本原因并非序列信息本身不足，而在于对序列的表示方式长期停留在人工构建的低阶统计特征层面。无论是氨基酸组成、多序列比对衍生的保守性矩阵（如 PSSM），还是信息熵与理化参数，本质上均属于预定义的特征压缩方式。这种方式假设蛋白功能可以通过有限维、可解释的统计量充分表达。然而，蛋白质序列本身蕴含着复杂的高阶依赖结构，包括远距离残基协同、进化耦合关系以及潜在的结构约束模式。这些信息虽然存在于原始序列中，但难以通过人工统计特征显式捕获。因此，传统方法的性能瓶颈更应理解为表示学习能力的瓶颈，而非序列信息量的瓶颈。

因此，问题的关键并不在于是否引入更多外部信息，而在于：是否能够在不增加额外模态数据的前提下，从原始序列中自动学习更具表达力的高阶表示。当研究焦点从“特征构建”转向“表示学习”时，基于自监督预训练的 PLM 应运而生[20-21]。与传统人工特征不同，PLM 直接在大规模序列数据上学习隐含的进化与结构模式，使序列表示从低阶统计描述升级为高维语义嵌入表示。这一转变并未改变信息来源（仍为序列），而是改变了信息利用方式，从而在表示层面突破了传统方法的结构性瓶颈。

综上所述，在深度表示学习方法引入之前，必需蛋白预测主要沿两条技术路径展开：其一基于 PPI 网络拓扑结构，通过中心性或模块化特征推断功能重要性；其二基于序列组成与功能注释，依赖人工构建的统计特征结合传统机器学习分类器进行判别。两类方法分别从系统结构与分子属性层面对蛋白必需性进行了建模，在数据规模有限、特征工程主导的阶段具有重要推动作用。网络驱动模型依赖于静态整合的 PPI 图谱，难以刻画条件依赖性与细胞情境差异；序列驱动模型虽摆脱了网络数据依赖，却长期停留在低阶统计特征表达框架，无法充分挖掘蛋白序列中隐含的远距离残基耦合与高阶进化约束模式。正是在这一背景下，基于自监督预训练的 PLM 逐渐成为新的技术转折点，为必需蛋白预测从“特征工程驱动”向“表示学习驱动”转型提供了理论与方法基础。

1.2.3　深度学习与 PLM 的兴起

蛋白质序列到结构与功能的映射关系具有显著的多尺度复杂性。传统计算方法通常基于人工构建的特征体系，如氨基酸组成统计、理化性质指标、多序列比对衍生的进化保守性评分及二级结构预测结果等，并结合支持向量机或随机森林等浅层模型进行建模。然而，此类方法的表达能力受限于特征设计的先验假设，难以系统刻画序列中的长程依赖关系与高阶非线性结构。深度学习方法的引入，从方法论层面突破了这一表达瓶颈。

在深度学习介入初期，研究重点在于利用深度神经网络自动学习序列表征，以替代传统依赖于专家经验的人工特征工程（如氨基酸组成、自相关系数等）。CNN 通过多层局部卷积滤波器提取序列片段中的模式特征，在蛋白质二级结构预测[44]以及翻译后修饰位点识别[45] 等任务中展现出较强的局部特征建模能力。由于卷积算子的局部感受野限制，传统 CNN 在缺乏多层堆叠或扩张卷积机制的情况下，难以充分整合蛋白序列中的长程依赖关系。为弥补这一不足，循环神经网络（RNN）及其变体长短期记忆网络（LSTM）被引入序列建模领域[46]，通过递归结构在时间维度上传递隐藏状态，从而在一定程度上缓解长程依赖建模中的梯度消失问题。随后，多项研究将双向 LSTM 应用于蛋白结构与功能预测任务，验证其在长序列建模中的优势。尽管监督学习方法在特定物种数据集上能够取得较高预测精度，但其性能高度依赖充足且分布一致的标注数据。必需基因的实验鉴定通常依赖饱和转座子诱变（Tn-Seq）等高通量技术[47]，该类实验流程复杂、成本高昂，且现有数据主要集中于少数模式生物[24,48]。在标注数据匮乏或物种分布发生变化的情况下，监督模型易受到过拟合与分布偏移问题的影响，从而导致泛化性能显著下降。

随着结构生物学的发展，研究者意识到蛋白质的功能及其必需性不仅取决于线性序列，更取决于其三维空间拓扑以及在复杂 PPI 中的交互地位。图神经网络（Graph Neural Networks, GNN）的引入为蛋白质建模提供了新的归纳偏置。通过将残基视为节点，将空间接触或功能关联视为边，GNN 利用消息传递机制实现节点表征的动态更新。其核心算子通常表达为：

$$h_i^{(l+1)} = \sigma\left(\sum_{j\in\mathcal{N}(i)} \alpha_{ij} W^{(l)} h_j^{(l)}\right) \tag{1.1}$$

其中，α_{ij} 代表注意力权重或聚合系数[49-50]。这种建模方式成功捕捉了必需蛋白在代谢网络中的“中心性-致死性”特征，即处于网络关键枢纽位置的蛋白更倾向于具有必需性。

然而，显式结构建模仍面临现实约束。一方面，实验解析的蛋白质三维结构数量远低于可获得的序列规模[51]，导致基于结构监督的模型训练数据受限；另一方

面，传统基于静态 PPI 网络的图模型通常忽略相互作用的时空条件依赖性，而大量研究表明蛋白质互作网络具有显著的动态模块化特征[38]。这种静态近似限制了模型在复杂生理环境下识别情境特异必需蛋白的能力。

随着自然语言处理领域表示学习思想的发展，研究者开始探索蛋白序列是否能够通过自监督方式学习统一的嵌入表示。早期工作如 Heinzinger 等[52]采用类 ELMo 架构在大规模蛋白序列上进行语言模型预训练，并验证其特征嵌入在二级结构与定位预测任务中的迁移能力，首次提出“蛋白序列语言化建模”的可行性。随后，Bepler 与 Berger[53] 将结构接触信息融入序列嵌入特征学习框架，通过联合监督与无监督信号优化表示空间，使可训练的嵌入特征同时编码序列与结构约束，为后续结构感知型表示学习奠定基础。

在此基础上，Alley[54] 等提出 UniRep 模型，在超过 2000 万条未标注蛋白序列上训练循环语言模型，并将隐藏状态作为统一序列嵌入。实验结果表明，该 embedding 在突变效应预测与蛋白工程优化任务中可直接迁移使用，且无需复杂特征工程。这一研究系统性证明蛋白序列可采用语言建模范式进行通用表示学习。

随后，Rao 等首先构建 TAPE 基准框架，对多种预训练策略在二级结构预测、接触预测与稳定性评估等任务上的迁移性能进行系统比较，结果表明预训练显著提升下游表现，并揭示模型容量与训练规模对性能具有重要影响[55]。然后进一步分析 Transformer PLM 内部注意力权重与真实残基接触图之间的相关性，发现部分注意力头能够显式对应空间邻近残基，表明预训练模型在无监督条件下已学习到结构相关信息[56]。

这一阶段的研究完成了从“任务驱动建模”向“统一表示学习”的方法学转变，使蛋白序列嵌入成为后续大规模预训练模型发展的理论基础。Transformer 架构的引入为蛋白序列建模提供了关键技术基础[57]。与循环神经网络相比，自注意力机制能够在单层计算中直接建立任意位置残基之间的依赖关系，从而有效建模蛋白序列中普遍存在的长程相互作用。考虑到三维结构中空间邻近残基往往在序列上相距较远，Transformer 的全局注意力结构天然契合蛋白折叠问题的依赖模式。

在结构预测层面，AlphaFold2 通过引入 Evoformer 模块，将 MSA 表示与基于注意力机制的残基对表示进行迭代交互更新，实现进化共变信息与空间约束的深度融合，并在 CASP14 评测中达到接近实验精度的三维结构预测水平[58]。尽管该模型仍依赖多序列比对作为输入，其成功从任务层面验证了注意力机制在整合跨残基依赖关系方面的有效性。结合前述无监督语言模型中结构信息的涌现现象，可以认为，基于注意力机制的深度架构为蛋白序列向结构映射提供了统一且可扩展的技术基础。

在此背景下，Rives 等构建 ESM-1b 模型，在超过 2.5 亿条 UniRef50 蛋白序列上进行掩码语言模型（masked language modeling, MLM）预训练[20]。该模型包含数亿级参数，通过随机遮蔽部分氨基酸残基并预测其类别，使模型被迫利用上下文信息重建局部序列，从而在无监督条件下学习序列内部的统计规律。不同于早期基于监督标签的模型，ESM-1b 的训练目标完全独立于特定下游任务，因而其隐藏表示具有更强的通用性。

更为重要的是，Rives 等对模型内部表示进行了系统分析。他们发现：（1）部分注意力头的权重分布与实验结构数据中的残基接触图高度相关；（2）隐藏层 embedding 可用于线性预测二级结构类别；（3）模型对特定保守位点的预测置信度与进化保守性评分呈显著相关关系。这些结果表明，模型在未显式接收结构或功能监督信号的情况下，自发学习到与空间结构和进化约束相关的统计特征。由此，蛋白序列的结构与功能信息被证明可以通过规模化自监督训练自然编码于潜在表示空间之中。

在 ESM 路线之外，ProtTrans 系列模型从架构与训练策略层面对 PLM 进行了系统扩展[59]。Elnaggar 等采用 BERT、XLNet 与 T5 等多种 Transformer 架构，在 UniRef50 及更大规模数据集上进行预训练，并构建参数规模从百万级到十亿级的多个模型版本。与 ESM 侧重结构信息验证不同，ProtTrans 更强调迁移学习能力的系统评估。研究者在亚细胞定位、二级结构预测、跨膜蛋白识别等多项任务上进行基准测试，结果显示预训练模型在无需复杂特征工程的情况下即可显著提升性能，且模型规模与训练数据规模的增加带来持续增益。这一结果从经验层面强化了“规模驱动规律”在蛋白建模中的适用性。

ESM 与 ProtTrans 的互补性在于：前者通过结构层分析证明预训练表示具有生物物理含量，后者通过多任务评估验证其迁移能力与泛化性能。两条路线共同构建了 PLM 的理论与实证基础。

由此，PLM 逐渐从“方法探索”演化为“统一建模范式”。其核心特征包括：（1）在大规模未标注序列上进行自监督预训练；（2）通过掩码预测任务学习上下文敏感表示；（3）在潜在空间中整合结构约束、进化保守性与功能信号；（4）通过下游微调或特征提取实现跨任务迁移。相较于早期任务特定型深度模型，PLM 不再针对单一生物学问题进行结构设计，而是提供一个统一的高维表示空间，使不同层级的蛋白质问题可以在同一表征框架内进行建模与比较。这一方法学转变标志着蛋白序列建模正式进入“预训练基础模型”阶段。

Meier 等利用预训练 PLM 进行零样本突变效应预测，发现突变前后序列的对数似然差值与实验测得的功能改变显著相关，表明模型学习到的概率分布能够反

映进化选择压力与功能约束强度[60]。ProteinBERT 通过联合序列建模与功能注释任务进行多任务预训练，在多项 GO 功能预测任务中表现出良好的迁移能力，进一步验证了预训练语言模型在功能注释领域的泛化潜力[61]。

综上所述，蛋白建模方法经历了由人工特征驱动向端到端深度学习、再向大规模自监督预训练与统一表示空间构建的演进过程。PLM 的形成不仅提升了下游预测任务的性能上限，更从方法论层面确立了“预训练基础模型 + 下游任务适配”的统一技术框架，为结构、功能及进化层面问题的联合建模提供了共享表示空间。

蛋白质序列作为一种蕴含高度复杂生物信息的“生命语言”，其计算表征的范式演迁构成了过去十年生物信息学研究的主旋律。从最初对理化特征的端到端监督学习，到对空间拓扑结构的显式建模，直至今日以大规模自回归或自编码预训练为核心的 PLM，这一演进过程不仅显著提升了预测精度，更深刻地改变了人类对基因必需性等复杂生物学属性的建模维度。

在必需蛋白预测任务中，PLM 的引入具有直接方法学意义：必需性本质上与蛋白的结构稳定性、功能模块化与进化约束密切相关，而这些信息在序列中往往以复杂的统计规律隐式存在。PLM 通过大规模预训练学习到的序列表示，能够在一定程度上缓解传统浅层序列特征表达能力不足的问题，为必需蛋白预测提供新的性能上限空间。

1.2.4　PIC 模型及其方法学框架

在基于 PLM 的必需蛋白预测研究中，PIC（Protein Importance Calculator）是目前具有代表性的序列驱动方法之一。该模型由 Kang 等发表于 Nature Computational Science（2024），系统性验证了大规模预训练 PLM 在蛋白必需性识别任务中的应用潜力 PIC 模型[62]。

在方法框架上，PIC 以预训练 PLM 作为序列表征模块，通过微调策略构建端到端分类模型，并在统一架构下实现跨层级预测体系。具体而言，PIC 构建了人类层面模型（PIC-human）、小鼠层面模型（PIC-mouse）以及 323 个细胞系特异模型（PIC-cell），并采用软投票（soft voting）集成策略整合细胞系预测结果，从而形成细胞层面的综合评估框架。该设计实现了从“单一物种预测”向“跨物种—跨细胞层级预测”的拓展，为蛋白必需性在不同生物学层面上的系统评估提供了方法学基础。

在序列表征层面，PIC 通过系统消融实验比较多种特征提取与池化策略，最终选用参数规模为 6.5 亿的 ESM-2 作为 backbone 模型，并结合平均池化生成蛋白级表示。在独立测试集上，PIC-human 的 AUROC 达到 0.9132，PIC-mouse 达到 0.8736；在细胞系层面，与 DeepCellEss 等既有方法相比，PIC 在 323 个细胞系上

的 AUROC 与 AUPRC 平均提升分别为 9.64% 与 10.52%，体现出预训练序列表示在必需性预测任务中的显著优势。

此外，PIC 基于模型输出概率构建蛋白必需性评分（protein essential score, PES），将传统二分类任务拓展为连续量化评估框架，并通过进化保守性、表达水平与功能富集分析验证其生物学一致性。这一设计为必需蛋白从“类别判定”向“程度刻画”的转变提供了可操作路径。

总体而言，PIC 的研究现状表明：在无需显式结构或网络特征的前提下，基于大规模预训练序列模型的微调策略能够实现高精度的蛋白必需性识别，并具备跨物种与跨细胞层级扩展能力。这确立了 PLM 驱动范式在必需蛋白预测领域中的可行性与稳定性。

然而，PIC 驱动模型所定义的“必需性”主要基于细胞存活或增殖能力的依赖性评估，其核心关注点在于维持基本生命活动所需的蛋白集合。对于高度功能特化且状态依赖性显著的免疫细胞而言，蛋白的重要性不仅体现在生存层面，更体现在炎症响应、吞噬活化及代谢重编程等功能维度。因此，如何在保持序列驱动建模范式一致的前提下，识别特定免疫细胞中的功能核心蛋白，仍然是尚未系统解决的问题。

基于此，本研究在继承 PLM 微调框架的基础上，将其应用于中性粒细胞特异情境，构建免疫细胞功能依赖蛋白识别流程，并以模型预测结果为线索提出潜在靶点蛋白。

1.3　问题的提出与研究设计

1.3.1　研究问题与总体思路

近年来，基于预训练 PLM 的蛋白质必需性预测方法取得显著进展。Protein Importance Calculator（PIC）通过整合人群遗传约束数据与细胞系 CRISPR 筛选数据，构建了多层级蛋白必需性预测框架，并提出 PES 用于量化蛋白在不同生物层面的重要程度[62]。该方法显著提升了蛋白必需性预测性能，为从序列层面识别功能关键蛋白提供了可靠工具。

然而，现有研究多集中于泛人类或整体细胞层面的核心必需蛋白识别，其应用目标主要围绕生命维持核心蛋白或肿瘤细胞依赖蛋白的筛选。对于特定免疫细胞群体，尤其是中性粒细胞这一高度动态、强应激的效应细胞，其潜在功能调控靶点尚未通过系统化计算模型进行挖掘。

中性粒细胞在吞噬体酸化、呼吸爆发及强氧化应激环境中执行免疫功能[3]。其中，急性炎症应答中以氧化爆发增强和颗粒/溶酶体功能负荷升高为特征的活化中

性粒细胞状态，尤其依赖维持酸化动力学、膜稳态和蛋白降解效率的关键分子。然而，目前尚缺乏基于深度学习必需性预测模型，在这一特定激活状态下系统筛选中性粒细胞相关候选靶点蛋白的研究。

因此，本研究的核心目标在于：基于深度学习蛋白必需性预测模型，系统筛选在活化中性粒细胞状态下可能具有条件性依赖的新靶点蛋白，并建立从计算预测到机制验证的研究流程。

围绕该目标，本研究形成“模型预测—候选筛选—机制验证”的总体思路。首先，利用预训练 PLM 提取序列表征，构建面向免疫相关依赖情境的必需性预测模型；其次，以 PES 为核心量化指标筛选高置信候选蛋白，并结合功能富集与结构特征分析评估其生物学合理性；最后，选取代表性候选蛋白开展分子结构模拟与体外实验验证，形成从计算筛选到机制解析的系统验证流程。在实验验证层面，本文进一步将研究状态具体界定为急性炎症应答中以氧化爆发增强和颗粒/溶酶体功能负荷升高为特征的活化中性粒细胞状态，并采用 PMA 刺激 HL-60 作为该状态的体外替代模型。

图 1.1　研究流程。该流程概述了本研究从免疫相关依赖蛋白必需性预测模型构建、候选蛋白筛选，到围绕活化中性粒细胞状态开展结构机制解析与实验验证的整体研究路径，强调“模型预测—生物学筛选—机制验证”的系统设计。

1.3.2　技术路线与论文结构安排

在技术实现层面，本研究采用 ProtT5 预训练 PLM 提取序列嵌入特征，并构建 Attention + MLP 多模块深度学习架构进行蛋白必需性预测。模型整体延续 Embedding–Attention–Prediction 的设计思路，并通过消融实验对 Attention 模块进行优化。实验结果显示，单头 Attention 结构在 AUPRC 指标上优于多头结构，提示在必需性预测任务中，集中式注意力机制更有利于关键序列区域的识别与表达。

模型性能通过 AUROC 与 AUPRC 等指标进行系统评估，并采用交叉验证保证模型稳健性。在模型预测结果基础上，本研究依据 PES 评分对蛋白进行排序筛选，构建高置信候选集合。通过比较不同模型版本中评分稳定的蛋白，识别在免疫相关依赖情境下持续高评分的核心候选蛋白。

随后，对候选蛋白开展理化与结构特征分析，包括等电点分布、表面电势特征、疏水性指数等指标，以评估其在免疫高应激环境中的潜在适应性。在此基础上，选取代表性候选蛋白，开展结构机制解析与验证。

全文结构安排如下：第一章为引言，系统阐述蛋白必需性研究背景与方法学发展现状；第二章介绍免疫相关依赖蛋白必需性预测模型的构建与优化；第三章

基于模型结果筛选中性粒细胞相关候选蛋白并开展结构与功能分析；第四章围绕活化中性粒细胞状态下的核心候选蛋白开展分子机制解析与实验验证；第五章总结研究成果并展望未来应用方向。

本章系统梳理了蛋白质必需性鉴定方法的技术演进路径，并评述了 PLM 在序列语义建模中的方法学突破。通过对中性粒细胞生物学特性及现有筛选技术局限的分析，可以明确当前研究在细胞类型特异性必需蛋白识别方面仍存在明显空白。

基于上述问题界定，后续章节将围绕免疫相关依赖情境下的蛋白必需性预测展开模型构建与验证，并在实验层面聚焦活化中性粒细胞状态，旨在利用深度学习方法从海量序列信息中挖掘维持中性粒细胞功能稳态的关键分子，预期能够发现新的免疫调控靶点蛋白。

第 2 章　模型的构建与优化

2.1　数据来源与免疫相关标签体系构建

蛋白质必需性具有显著的层级差异性与情境依赖性。在此基础上，本研究重新组织数据来源，并构建“基础生存约束 + 免疫相关功能依赖”双标签体系。

2.1.1　人类遗传约束数据

为刻画蛋白质在人类种群尺度上的基础功能重要性，本研究引入 gnomAD v4.1 数据库提供的基因层面遗传约束指标 LOEUF（Loss-of-function Observed/Expected Upper bound Fraction）[63]。该指标建立在大规模外显子测序数据对功能缺失变异（loss-of-function, LoF）进行统计建模的框架之上，其理论基础来源于 ExAC 项目对 60,706 例人类外显子数据的系统分析[64]。该研究通过构建突变率驱动的中性模型，对每个基因在无选择压力假设下的 LoF 变异期望数量进行估计，从而为定量评估基因所受负选择约束程度提供了统计基准。

对于任一基因 g，设其观测到的 LoF 变异数量为 O_g，在中性突变模型下的期望 LoF 变异数量为 E_g，则有

$$E_g = \sum_{i \in g} \mu_i \cdot C_i, \tag{2.1}$$

其中 μ_i 表示在特定三核苷酸序列背景下第 i 个位点的突变率，C_i 表示覆盖度与检测概率校正项。由此可定义观测/期望比值（observed/expected, O/E）

$$R_g = \frac{O_g}{E_g}. \tag{2.2}$$

当 $R_g \ll 1$ 时，说明该基因中的 LoF 变异显著少于期望值，提示其在种群层面受到强负选择压力。为提高估计的稳健性，gnomAD 对 R_g 构建置信区间，并将其 90% 置信区间上界定义为 LOEUF，即

$$\mathrm{LOEUF}_g = U_{0.90}(R_g), \tag{2.3}$$

其中 $U_{0.90}(\cdot)$ 表示 R_g 的 90% 置信上界。由于采用上界估计，该指标在统计上具有保守性：即便观测变异数较少，也不会过度夸大基因的不耐受程度。因此，LOEUF_g 越小代表基因对功能缺失越不耐受，进化约束越强。

从生物学意义上看，LOEUF 反映的是基因在长期进化过程中所承受的群体选择压力，可近似理解为种群尺度的功能必要性或剂量敏感性信号。然而，该指标

并不区分组织或细胞类型，其估计结果更接近跨组织平均选择效应。因此，本研究将 LOEUF 用作 Human-level 必需性的监督来源，而不将其视为特定中性粒细胞激活状态的直接表征。

在具体标签构建过程中，我们以 LOEUF = 0.6 作为区分阈值，定义

$$y_g = \begin{cases} 1, & \text{LOEUF}_g \leqslant 0.6, \\ 0, & \text{LOEUF}_g > 0.6, \end{cases} \tag{2.4}$$

其中 $y_g = 1$ 表示种群层面功能不耐受（Human-level essential），$y_g = 0$ 表示相对耐受。通过基因到蛋白的映射，将上述标签转化为蛋白层面的监督信号，最终构建 15,234 个必需蛋白标签与 53,642 个非必需蛋白标签。

基于上述数据，我们训练 Human-level 模型学习从蛋白序列 **s** 到种群层面必需性概率的映射：

$$PES_{\text{human}}(\mathbf{s}) = \Pr(y = 1 \mid \mathbf{s}; \theta), \tag{2.5}$$

其中 θ 表示模型参数，PES_{human} 定义为 Human-level Protein Essentiality Score。该评分反映蛋白序列所对应的进化约束强度，为后续与 Immune-level 模型输出进行比较奠定基准。通过在统一序列空间中建立种群尺度的必需性表征，本研究进一步引入免疫细胞 CRISPR 依赖数据进行情境适配，从而实现从一般必需性到免疫相关依赖性的层级建模。

2.1.2　免疫细胞系必需性数据

为刻画蛋白质在免疫相关细胞背景中的功能依赖性，本研究引入 Project Score 数据库提供的基因必需性数据。该数据库来源于 Nature 2019 年报道的全基因组 CRISPR–Cas9 敲除筛选研究[30]。在该研究中，研究者通过包含数万个 sgRNA 的文库对数百个人类细胞系进行系统性基因敲除，并基于 sgRNA 丰度变化评估基因对细胞适应度（cellular fitness）的影响。

在实验原理层面，设第 c 个细胞系中第 g 个基因对应 sgRNA 在敲除前后的丰度分别为 $A_{g,c}^{(0)}$ 与 $A_{g,c}^{(t)}$，则其对数丰度变化可表示为

$$\Delta_{g,c} = \log_2\left(\frac{A_{g,c}^{(t)}}{A_{g,c}^{(0)}}\right). \tag{2.6}$$

当基因敲除显著降低细胞增殖能力时，其对应 sgRNA 在群体中的比例将逐渐减少，从而表现为显著负的丰度变化。基于此原理，研究者进一步构建经 copy-number 校正与批次效应校正后的基因依赖评分，用以量化基因对特定细胞系存活的依赖强度。

在数据库发布阶段，Project Score 数据库在连续依赖评分基础上提供了二值化的必需性标签矩阵。该矩阵可形式化表示为

$$y_{g,c} \in \{0, 1\}, \tag{2.7}$$

其中 $y_{g,c} = 1$ 表示基因 g 在细胞系 c 中被判定为必需基因，$y_{g,c} = 0$ 表示非必需基因。该二值矩阵已在 PIC 模型中作为细胞层面必需性监督数据使用[62]。

在本研究中，为聚焦免疫相关依赖信号，我们从 Project Score 全部细胞系集合 C_{all} 中筛选出 14 个具有免疫来源或免疫相关表型特征的细胞系，构建免疫子集 C_{immune}。对于任一基因 g，定义其在免疫子集中的必需性比例为

$$\bar{y}_g^{immune} = \frac{1}{|C_{immune}|} \sum_{c \in C_{immune}} y_{g,c}. \tag{2.8}$$

该比例反映基因在免疫细胞背景下被判定为必需的频率。为构建 Immune-level 监督标签，我们定义

$$z_g = \begin{cases} 1, & \bar{y}_g^{immune} \geqslant 0.8, \\ 0, & \text{otherwise}, \end{cases} \tag{2.9}$$

$z_g = 1$ 表示该基因在免疫谱系内部表现为一致性依赖基因。

需要强调的是，尽管 Project Score 数据覆盖 300 余个不同来源的细胞系[30]，本研究并未直接纳入全部细胞系进行训练，而是基于研究目标限定细胞谱系空间，仅保留免疫相关子集。在条件概率意义下，本研究建模的是

$$P(z = 1 \mid \mathbf{s}, \text{immune context}), \tag{2.10}$$

而非无条件概率 $P(z = 1 \mid \mathbf{s})$。该策略能够降低跨谱系异质性带来的噪声干扰，提高模型对免疫相关依赖信号的分辨能力。需要说明的是，这里的 Immune-level 反映的是免疫谱系细胞中的广义依赖特征，并不直接等同于单一实验刺激下的中性粒细胞状态；在后续实验验证部分，本文进一步将生物学状态收缩为急性炎症应答中以氧化爆发增强和颗粒/溶酶体功能负荷升高为特征的活化中性粒细胞状态。

基于上述免疫必需性标签，我们训练 Immune-level 模型学习蛋白序列 $\mathbf{s}$ 与免疫相关依赖性之间的映射关系：

$$PES_{\text{immune}}(\mathbf{s}) = \Pr(z = 1 \mid \mathbf{s}; \phi), \tag{2.11}$$

其中 ϕ 表示模型参数。通过与 Human-level 模型输出进行比较，可进一步定义

$$\Delta PES(\mathbf{s}) = PES_{\text{immune}}(\mathbf{s}) - PES_{\text{human}}(\mathbf{s}), \tag{2.12}$$

用于识别在种群层面并非高度受限，但在免疫相关细胞背景中表现出显著依赖的

候选蛋白。

2.1.3　蛋白质序列获取与标准化处理

在监督标签层面，无论是基于 LOEUF 的人群层面功能不耐受信息，还是基于 Project Score 的细胞依赖信息，原始数据均以基因为基本单位。然而，本研究的模型输入为蛋白质氨基酸序列，因此需要在建模前完成从“基因层面标签”到“蛋白层面序列”的标准化映射。

首先，根据 Ensembl Gene ID，将基因映射至 UniProt 数据库（UniProtKB/Swiss-Prot）对应条目[65]。使用 Ensembl BioMart API 编写脚本从 BioMart 中直接获取蛋白质序列。为避免不同转录本导致的序列歧义问题，本研究遵循 PIC 框架[62]，仅保留每个基因对应的 canonical isoform 作为代表序列。若某基因存在多个蛋白条目，则优先选择经过人工注释且标记为“Reviewed”的 Swiss-Prot 条目；对于无法匹配至唯一蛋白序列的基因，则予以剔除。

在获得蛋白序列后，进一步进行如下预处理步骤：（1）去除含有非标准氨基酸字符（如 B、Z、J、U、O）的序列；（2）过滤极短序列（长度 < 30 aa），以避免噪声蛋白或片段序列对模型训练造成干扰；（3）对重复序列进行去重，确保同一氨基酸序列不会在训练集中重复出现；（4）对长度超过预设上限的序列进行截断或分段处理，以满足预训练 PLM（ProtT5）的最大输入长度限制。

最终获得用于建模的蛋白序列集合 $\{s_i\}$，并将基因层面的监督标签精确映射至对应的蛋白序列层面。同时，为保证样本的可追溯性与跨数据库一致性，每条序列均保留其唯一蛋白标识符（Protein ID）。

因此，构建的训练数据集可形式化表示为：

$$\mathcal{D} = \{(p_i, s_i, y_i)\}_{i=1}^{N}, \tag{2.13}$$

其中：

- p_i 表示第 i 个蛋白的唯一标识符（如 UniProt ID）；
- s_i 表示对应蛋白的氨基酸序列；
- y_i 表示其必需性监督标签；
- N 为最终纳入建模的蛋白样本总数。

在本研究中，监督标签 y_i 根据预测层级的不同具有不同定义形式。形式上定义为二分类变量：

$$y_i \in \{0, 1\}, \tag{2.13}$$

其中 1 表示必需蛋白，0 表示非必需蛋白。

进一步地，根据不同预测层级，可构建两个层级特异性数据集：

$$\mathcal{D}^{(H)} = \{(p_i, s_i, y_i^{(H)})\}_{i=1}^{N_H}, \tag{2.14}$$

$$\mathcal{D}^{(I)} = \{(p_i, s_i, y_i^{(I)})\}_{i=1}^{N_I}, \tag{2.15}$$

其中：

- $y_i^{(H)}$ 表示 Human-level 必需性标签；
- $y_i^{(I)}$ 表示 Immune-level 必需性标签；
- N_H 与 N_I 分别表示对应层级的数据规模。

由于蛋白质必需性最终体现为蛋白分子功能缺失对细胞适应度或个体存活能力的影响，因此将基因层级标签信息映射至蛋白序列层级具有明确的生物学合理性。

2.2　模型架构设计

2.2.1　序列嵌入模块：ProtT5 表示学习机制

为从蛋白质氨基酸序列中提取具有结构与功能语义的信息，本研究采用基于 Transformer 架构的 PLM ProtT5 作为序列嵌入层。ProtT5 属于 ProtTrans 框架中的预训练模型，通过在大规模未标注蛋白质数据库上进行自监督学习，构建通用的蛋白序列表示空间。

ProtT5 基于 T5（Text-to-Text Transfer Transformer）架构构建，其核心为多层 Transformer 结构。Transformer 通过自注意力（Self-Attention）机制在单层内建立序列中任意两个位置之间的依赖关系，从而实现全局上下文建模。相比基于递归或卷积的序列模型，该结构能够有效捕捉远距离残基之间的协同关系，这对于蛋白质功能建模尤为重要，因为催化位点、结构域耦合或功能调控区域往往分布于序列的不同位置。在本研究中，主要使用 ProtT5 编码器部分输出残基级嵌入表示。

ProtT5 的训练采用自监督掩码语言建模（Masked Language Modeling, MLM）任务。设蛋白质序列为：

$$S = (a_1, a_2, \cdots, a_L) \tag{2.16}$$

在预训练阶段，随机选择一部分位置集合 $M \subset \{1, \cdots, L\}$ 进行遮蔽。模型的

训练目标是预测被遮蔽位置的真实氨基酸类型，其损失函数定义为：

$$\mathcal{L}_{MLM} = -\sum_{i \in M} \log P_\theta(a_i \mid S_{\setminus M}) \tag{2.17}$$

其中：

- $\mathcal{L}_{MLM}$ 为掩码语言建模损失；
- M 为被遮蔽位置集合；
- a_i 为第 i 个位置的真实氨基酸；
- $S_{\setminus M}$ 表示将集合 M 中位置替换为 <mask> 后的输入序列；
- $P_\theta(a_i \mid S_{\setminus M})$ 为模型在参数 θ 下对该位置残基的预测概率；
- 负号表示最小化负对数似然，即等价于最大化正确残基的对数概率。

该训练目标迫使模型利用上下文信息恢复缺失残基。由于蛋白质序列在进化过程中受到结构稳定性、功能活性及选择压力的约束，残基之间存在复杂统计依赖关系，因此最小化上述损失的过程，本质上是在逼近蛋白质的进化统计分布。模型通过学习“在给定上下文条件下哪种氨基酸更可能出现”，隐式捕捉了残基共现模式与进化保守性信号。

经过预训练后，ProtT5 将离散氨基酸序列映射为残基级嵌入矩阵：

$$\mathbf{H} = f_\theta(S) \in \mathbb{R}^{L \times d} \tag{2.18}$$

其中 $\mathbf{h}_i \in \mathbb{R}^d$ 表示第 i 个残基在全局语境下的上下文嵌入表示。

已有研究表明，该嵌入空间能够通过简单线性映射预测二级结构、溶剂可及性以及功能域类别，说明其隐藏表示中已编码与蛋白质结构和功能相关的统计特征[59]。因此，该表示不仅包含序列级信息，还隐式包含结构约束与进化选择压力的痕迹。

蛋白质必需性通常与功能域完整性、关键催化位点保守性及结构稳定性密切相关，这些因素在进化过程中具有显著保守性，并体现在残基共现统计模式中。因此，可将必需性预测表示为：

$$\hat{y} = g_\phi(f_\theta(S)) \tag{2.19}$$

其中 $f_\theta(S)$ 为 ProtT5 嵌入表示，g_ϕ 为后续判别网络。

由于嵌入空间中已编码与结构和功能相关的统计信息，必需与非必需蛋白在该连续语义空间中往往具有不同分布特征，从而使必需与非必需蛋白在嵌入空间

中呈现可区分的分布特征。

图 2.1　ProtT5 原理示意图。该图展示了预训练蛋白语言模型从氨基酸序列输入、上下文表征学习到下游任务迁移的基本框架，说明序列嵌入如何作为后续必需性判别模块的统一表示基础。

2.2.2　分类模块

在获得预训练 PLM 输出的残基级上下文嵌入表示后，仅依赖原始嵌入向量仍难以充分刻画“蛋白质必需性”这一复杂生物学表型。蛋白质是否为必需蛋白，往往取决于其承担的核心分子功能、结构稳定性以及在调控网络中的关键位置，这些属性在序列层面通常表现为多尺度特征的组合。因此，本研究在嵌入表示之上构建分类模块（Classifier Module），对提高判别能力有重要意义。

设蛋白序列经 PLM 编码后得到残基嵌入矩阵：

$$\mathbf{H} = [h_1, h_2, \cdots, h_L] \in \mathbb{R}^{L\times d}, \tag{2.20}$$

其中 L 表示序列长度，d 为嵌入维度，h_i 为第 i 个氨基酸残基在全局语境下的上下文表示。基于此，构建如下分层加工流程：

$$\mathbf{H} \xrightarrow{\text{Attention}} \mathbf{Z}_a \xrightarrow{\text{MLP}} \hat{y} \in [0, 1].$$

在此基础上本研究系统比较了三类结构建模机制：

（1）基线：MLP　最简单的策略是对嵌入矩阵进行全局池化（如平均池化）后直接输入 MLP 进行分类：

$$\mathbf{h}_1 = \text{ReLU}(W_1\mathbf{Z}_c + b_1), \tag{2.21}$$

$$\hat{y} = \text{Sigmoid}(W_2\mathbf{h}_1 + b_2). \tag{2.22}$$

输出 $\hat{y}$ 表示蛋白质在特定细胞语境下为必需蛋白的预测概率。该策略并不显示建模蛋白质残基之间的依赖，进对 PLM 所编码的语义信息进行判别。该结构作为基线模型，用于评估 PLM 嵌入表示本身的判别能力。

图 2.2　MLP 机制示意图。该图给出了基线分类器对预训练嵌入进行全局汇聚与非线性映射的过程，用于评估在不显式建模残基间依赖的条件下，嵌入表示本身对必需性判别的贡献。

（2）局部结构：CNN　考虑到蛋白质功能不仅依赖全局结构稳定性，也可能受到局部连续残基组合模式的影响，例如短功能肽段、活性位点周围微环境或结合基序等，已有研究表明 CNN 能够有效捕捉生物序列中的局部 motif 特征[66-67]。在蛋

白质功能预测任务中，CNN 常用于提取局部残基组合模式，以增强模型对微观结构信号的感知能力。因此，本研究进一步探索性引入一维 CNN 模块，卷积操作可表示为：

$$z_j = \sigma\left(\sum_{i=0}^{k-1} W_i \cdot Z_{a,j+i} + b\right), \tag{2.23}$$

其中 k 为卷积核尺寸，表示局部感受野范围，W_i 为卷积核参数，$\sigma(\cdot)$ 为非线性激活函数。

卷积层在嵌入空间中实现局部邻域特征的非线性组合，用于强化局部拓扑特征表达，从而评估局部模式是否对必需性判别具有额外贡献。

图 2.3　CNN 机制示意图。该图展示了一维卷积模块在残基嵌入空间中提取局部连续模式的过程，用于刻画短程序列基序与局部结构信号对蛋白必需性预测的潜在增益。

（3）全局依赖：注意力机制　蛋白质必需性通常涉及跨结构域协同、长程调控关系以及功能核心区域之间的耦合。例如，催化位点与调控区域之间的空间协同，或跨膜结构与胞内信号调节片段之间的功能耦合，均可能决定蛋白质在细胞中的生存必要性[68-69]。因此，模型首先引入注意力机制对残基表示进行加权整合，以突出对判别贡献更大的关键位点。

对每个残基嵌入 h_i 计算注意力权重：

$$\alpha_i = \frac{\exp(\mathbf{w}^\top h_i)}{\sum_{j=1}^{L} \exp(\mathbf{w}^\top h_j)}, \tag{2.24}$$

并得到加权全局表示：

$$\mathbf{Z}_a = \sum_{i=1}^{L} \alpha_i h_i. \tag{2.25}$$

该过程本质上是在嵌入空间中执行一次任务驱动的重采样，使模型能够自动识别与必需性相关的关键残基区域，如催化核心、结合界面或功能结构域。相比简单的平均池化策略，注意力机制不仅增强了模型对长程依赖关系的表达能力，同时提高了表示的可解释性，为后续功能区域分析提供理论基础。

图 2.4　Attention 机制示意图。该图说明模型如何通过任务驱动的注意力加权，对残基级嵌入进行全局重整合，从而突出对必需性判别贡献更大的关键位点与功能区域。

（4）多尺度融合探索与结构确定　除单独引入局部或全局特征增强机制外，本研究进一步构建了 Attention 与 CNN 融合结构（Attention + CNN + MLP），以验证局

部连续残基模式与跨残基全局依赖是否在本任务中具有互补作用。该结构旨在在全局依赖重构的基础上进一步强化局部拓扑特征表达，从而实现多尺度特征整合。

通过系统消融实验对 MLP、CNN + MLP、Attention + MLP 以及 Attention + CNN + MLP 等结构进行比较分析，结果表明，在预训练 PLM 已充分编码局部语义信息的前提下，全局依赖增强机制（Attention）对必需性预测的贡献更为显著，而卷积结构所带来的局部增强未转化为稳定的综合性能提升。因此，在保证模型表达能力的同时，为避免不必要的结构复杂化与参数冗余，本研究最终采用 Attention + MLP 作为默认分类架构。

2.3　消融实验与模型优化

2.3.1　模块消融实验

为系统评估不同特征增强策略在免疫相关依赖蛋白预测任务中的贡献，本研究在统一的嵌入表示的基础上构建四种分类结构：

1. MLP：性能基线模型。
2. CNN + MLP：局部特征增强。
3. Attention + MLP：全局依赖增强。
4. Attention + CNN + MLP：多尺度融合。

并在相同测试集上进行比较。为全面评估模型在蛋白必需性预测任务中的表现，本研究采用 Accuracy、Precision、Recall、F1-score、AUROC 及 AUPRC 作为性能评价指标。

设：

- TP（True Positive）：正确预测为必需蛋白的样本数；
- TN（True Negative）：正确预测为非必需蛋白的样本数；
- FP（False Positive）：误判为必需蛋白的样本数；
- FN（False Negative）：误判为非必需蛋白的样本数。

则各指标定义如下：

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \tag{2.26}$$

$$\text{Precision} = \frac{TP}{TP + FP} \tag{2.27}$$

$$\text{Recall} = \frac{TP}{TP + FN} \tag{2.28}$$

$$\text{F1-score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \tag{2.29}$$

其中，AUROC 用于衡量模型在不同判别阈值下对正负样本的整体排序能力；AUPRC 则在类别不平衡场景下更能反映模型对正类样本的识别能力。各模型在独立测试集上的分类性能结果如表 2.1 所示。

表 2.1　不同结构增强策略在测试集上的性能比较

模型结构	Accuracy	Precision	Recall	F1-score	AUROC	AUPRC
MLP	0.8008	0.5269	0.7961	0.6341	0.8813	0.7210
CNN + MLP	0.6606	0.3856	0.9517	0.5488	0.9224	0.8083
Attention + MLP	0.8826	0.7216	0.7023	0.7118	0.9059	0.7873
Attention + CNN + MLP	0.8569	0.5904	0.7232	0.6501	0.8799	0.6528

通过表 2.1 的数据对比分析，发现仅采用 MLP 结构，模型已取得较高的 AUROC（0.8813）与 AUPRC（0.7210），说明预训练 PLM 在嵌入空间中已隐式编码丰富的序列语义与进化约束信息。

在此基础上，引入 CNN 后，模型 Recall 值提升至 0.9517，但 Precision 值降至 0.3856，导致 F1-score 下降。该现象表明，卷积结构虽然强化了对局部连续残基模式的特征表达，使模型对正类样本高度敏感，但由于缺乏全局依赖的约束，模型难以在全长序列背景下区分相似的局部噪声，产生了大量假阳性预测，显著削弱了判别边界的稳定性。

相比之下，Attention+MLP 结构在 Accuracy（0.8826）、Precision（0.7216）、F1-score（0.7118）以及 AUROC（0.9059）等指标上均取得优秀表现，这说明注意力机制通过任务驱动的残基动态加权，能够有效地从高维嵌入中提取关键功能区域并抑制背景噪声，在捕捉全局长程依赖的同时，构建了更为稳健且均衡的分类决策边界。

进一步引入 CNN 构建 Attention+CNN+MLP 融合结构，整体性能较 Attention+MLP 没有提升，部分指标反而下降，说明在预训练嵌入已充分编码局部语义信息的前提下，额外引入卷积结构未能提供有效互补，反而可能因参数冗余或特征过拟合引入了干扰信号。

综上所述，在当前任务设定下，全局依赖增强机制是性能提升的主要驱动因素，

而局部卷积增强未带来稳定综合性能提升。因此，本研究最终采用 Attention+MLP 作为默认分类架构。

2.3.2　Attention Head 数量消融实验

在确定 Attention+MLP 为核心结构后，本研究进一步考察注意力 head 数对模型性能的影响。不同 head 数模型在验证集与测试集上的性能如表 2.2所示。

表 2.2　不同注意力 head 数的性能比较

Head 数	AUPRC	AUROC	Acc
1	0.8245	0.9272	0.8752
2	0.7897	0.9182	0.8593
4	0.7403	0.8958	0.8315
8	0.7380	0.8939	0.8459
16	0.7245	0.8922	0.8229

从表 2.2可以观察到，单头模型在 AUPRC（0.8245）与 AUROC（0.9272）指标上均取得最佳表现。随着 head 数增加，性能呈现整体下降趋势，其中 16-head 模型在 AUPRC 上较单头结构下降 0.1000。该趋势在验证集与测试集上保持一致。

训练过程中验证集 AUPRC 与 AUROC 的变化趋势（图 2.5（a）、图 2.5（b））进一步表明，单头模型在早期阶段即达到较高性能水平，并在后期保持稳定优势；多头模型虽具更高参数容量，但未表现出持续性能增益。

测试集 PR（Precison Recall）与 ROC（Receiver Operating Characteristic）曲线（图 2.5（c）、图 2.5（d））显示，单头模型在高召回区间维持更高 Precision，其曲线整体位于其他模型之上，说明其在不同判别阈值下具有更优的区分能力。上述

图 2.5　注意力机制多头结构的消融实验结果，显示单头注意力在验证集与测试集上均保持最优且最稳定的性能表现。(a) 不同注意力头数模型在验证集上的 AUPRC 随训练轮次变化；(b) 不同注意力头数模型在验证集上的 AUROC 随训练轮次变化；(c) 不同注意力头数模型在测试集上的 PR 曲线比较；(d) 不同注意力头数模型在测试集上的 ROC 曲线比较。

结果表明，在当前任务设定下，多头注意力机制未带来有效的表示空间分解优势。预训练 PLM 嵌入已编码多维语义与结构约束信息，单头注意力足以完成任务驱动的关键残基加权与全局依赖重构。增加 head 数可能导致特征子空间过度分解，从而削弱全局一致性，并在有限数据规模下引入冗余参数与潜在过拟合风险。因此，综合验证集与测试集结果，本研究最终采用单头 Attention 作为默认配置。

2.4　模型训练与结果

2.4.1　数据流转与样本分布

在完成基因标识符映射及序列清洗后，本研究对数据流转过程中的损耗进行了系统统计。数据从原始数据库到最终处理后序列的流转概览如表 2.3 所示。

表 2.3　数据流转与筛选损耗统计表

阶段	条数	说明
原始记录	~180,000	包含非编码、LOEUF 缺失或预测不确定的条目
映射蛋白	68,876	严格筛选编码转录本并成功映射序列
最终处理序列	**68,876**	完成终止子分类及去止步码处理后的标准建模序列

处理后序列中必需与非必需样本的具体比例见表 2.4。统计结果显示，必需样本与非必需样本的数量比约为 1 ： 3.5，这种显著的类别不平衡特征是模型训练中的核心挑战。若直接使用标准的交叉熵损失函数，模型可能通过倾向于预测多数类（非必需蛋白）来换取整体准确率的提升，从而导致对关键必需蛋白的召回率下降。为此，本研究在后续模型优化中采取了以下策略：

- **评价指标优化**：引入 AUROC 和 AUPRC 作为核心评价指标，以更客观地衡量模型在类别不平衡场景下对正类样本的识别能力。
- **加权随机采样**：在数据加载阶段，通过计算类别频率的倒数作为采样权重对数据集进行重采样，确保在每个训练批次内正负样本的出现概率趋于均衡，从而缓解模型对多数类（非必需蛋白）的预测偏好。
- **损失函数加权**：计划在训练过程中根据类别频率的倒数对损失函数进行加权处理，强制模型增加对少数类（必需蛋白）误分类的惩罚力度。

表 2.4　建模数据集类别分布统计

类别	标签	条数	比例
必需	1	15,234	22.1%
非必需	0	53,642	77.9%
总计	-	68,876	100.0%

2.4.2　训练环境与超参数设置

模型训练在 Ubuntu 22.04 操作系统环境下完成，核心硬件采用单卡 NVIDIA RTX 4090 GPU (24GB)。深度学习框架选用 PyTorch，并利用 Hugging Face 的 Trans-

formers 库调用预训练 ProtT5 权重。

具体的训练超参数配置如下：

- **优化器**：采用 AdamW 优化器，设置权重衰减为 1×10^{-4}。
- **学习率**：初始学习率设定为 1×10^{-5}，采用余弦退火策略进行动态调整。
- **损失函数**：针对类别不平衡问题，引入正样本加权系数 $w_{pos} = 3.5$。
- **训练细节**：批次大小设定为 256，训练周期为 15 轮，并开启早停机制以防止过拟合。

2.4.3　训练过程与结果分析

如图 2.6(a) 所示，训练损失在整个训练阶段持续下降，由初始阶段的 0.48 降至第 15 个 epoch 的 0.18，表明模型参数在不断逼近经验风险最小化解。与此同时，验证损失在前期快速下降，并在第 10 个 epoch 之后逐渐趋于稳定，在第 15 个 epoch 达到最低值 0.3732，未出现显著回升现象。这一现象说明模型在训练过程中未发生明显过拟合。

同时如图 2.6(b) 所示，验证集损失在第 12 个 Epoch 达到最低值 0.3732，此后虽训练损失仍缓慢下降，但验证损失未进一步改善。验证集 AUROC 从首个 epoch 的 0.8626 快速提升至第 15 个 epoch 的 0.9281，PR-AUC 同步提高至 0.9334，后期提升幅度显著减小并逐步进入平台期。该现象表明模型已充分学习到蛋白序列嵌入中蕴含的进化约束与功能语义信息，泛化性能趋于收敛。

在监督学习框架下，训练目标本质上是最小化训练集损失，因此训练误差持续下降是正常现象。然而，模型性能的关键评判标准并非训练误差，而是验证集上的泛化能力。随着训练轮次增加，模型可能逐渐开始拟合训练数据中的细微噪声，从而对泛化性能贡献有限。基于验证集损失与性能指标的综合考量，早停策略在第 15 个 epoch 终止训练，并选取验证集性能最优的模型参数用于后续测试。

从统计学习理论角度来看，当前训练过程呈现“训练误差持续降低、验证误差趋于稳定、泛化间隙保持可控”的特征，说明模型复杂度与样本规模之间达成了较为合理的平衡。在偏差-方差权衡框架下，模型已进入低偏差区域，而未观察到显著方差膨胀迹象，因此无需进一步延长训练周期。

为进一步评估模型的泛化能力，本研究选取验证集性能最优的模型参数，并在独立测试集上进行系统评估。测试集性能指标如表 2.5 所示，在必需蛋白仅占约 22% 的类别不平衡条件下，模型仍取得 0.8245 的 AUPRC 与 0.8187 的 Recall，表明其对少数类样本具有较高敏感性。Precision 为 0.6758，反映模型在保证召回率的同时维持了相对合理的误报控制能力。综合指标 F1-score 为 0.7404，说明模型在精准度与覆盖度之间取得了较为均衡的表现。

表 2.5　模型在独立测试集上的性能指标

指标	Accuracy	Recall	Precision	F1-score
评估值	0.8752	0.8187	0.6758	0.7404

独立测试集的 ROC 曲线与 PR 曲线分别见图 2.6(c) 与 (d)，AUC 分别达到 0.9272 与 0.8245，表明模型具有较强判别能力。相较于验证集 AUROC（0.9281），测试集性能无差别，说明模型泛化稳定。

整体而言，模型在独立测试集上表现出稳定且可泛化的判别能力，为后续免疫相关依赖模型构建与中性粒细胞特异依赖蛋白筛选提供了可靠的算法基础。

图 2.6　模型训练过程与性能评估结果，表明模型在训练后期达到稳定收敛，并在独立测试集上保持良好的判别能力。(a) 训练集与验证集损失随训练轮次的变化；(b) 验证集 AUROC 与 PR-AUC 随训练轮次的变化；(c) 独立测试集 ROC 曲线；(d) 独立测试集 PR 曲线。

本章完成了基于 ProtT5 嵌入与单头注意力机制的必需性预测模型构建。独立测试集上的 AUROC 与 AUPRC 指标验证了模型在高维语义表示空间中的判别能力与稳健性。下一章将进一步利用模型输出的 PES，对免疫相关依赖情境下的蛋白功能依赖关系进行系统分群与特征解析。

第 3 章　中性粒细胞候选必需蛋白筛选与特征分析

3.1　基于 PES 评分的蛋白功能分群

本研究旨在识别中性粒细胞执行特定功能时不可或缺的候选蛋白。通过构建 Human-level 与 Immune-level 双模型评分体系，旨在从群体进化约束与细胞情境依赖两个维度对蛋白必需性进行定量评估。

对两模型输出的 PES 进行整体相关性分析。如图 3.1(a) 所示，横轴与纵轴分别是 PES_{human} 和 PES_{immune}。统计分析表明，两模型输出 PES 的 Pearson 相关系数仅为 $r = 0.073$ ($p < 0.001$)。散点图呈现高度弥散的分布特征，而非向 $y = x$ 对角线集中。这种极低的相关性说明，蛋白在物种水平受到的进化压力与其在特定免疫细胞中的生存贡献之间并不存在显著的线性对应关系。

通过 $PES = 0.8$ 的阈值线进行划分，可以观察到明显的两个模型的蛋白 PES 分布偏离现象：

- 散点图中右下区域集中了大量在群体层面表现为高必需性但免疫细胞层面非必需的蛋白。由于中性粒细胞是高度分化且不具备增殖能力的终末细胞，许多维持细胞周期或基础发育的蛋白在其特定的生理周期内表现出较低的依赖权重，呈现出明显的背景特异性。
- 与之对应，左上区域存在大量群体层面在进化上相对耐受、但在免疫背景下得分显著升高的蛋白。这部分蛋白反映了中性粒细胞内部存在一套独立于基础生存需求的功能调节网络，体现了必需性得分随细胞情境变化的动态调整。

这说明，Human-level 与 Immune-level 模型在必需性判定上存在显著的维度差异。位于左上象限的蛋白集合虽然在广义进化背景下表现出较高的功能冗余性，但在中性粒细胞特定的生理语境下却具有较高的依赖得分。这种预测结果的非一致性直观地展示了两模型在捕捉情境特异性必需基因时的差异化侧重。这证实了综合考虑双模型得分的必要性，并为后文中确立分群阈值及功能集合划分提供了依据。

在证实双模型预测结果存在显著差异后，需进一步量化其分布规律，以确立科学的候选蛋白筛选标准。图 3.1(c) 展示了两模型在全基因组范围内的得分密度分布情况。PES_{human} 呈现出典型的双峰分布格局：在 $PES \approx 0.1$ 附近存在一个代表非必需蛋白的宽峰，而在 $PES > 0.8$ 的高分区间则形成了一个显著的尖峰。这种分布态势反映了 Human-level 模型能够清晰地界定出进化受限程度极高的核心必需基因，即那些维持生物体基本生存的基因集合。

相比之下，Immune-level 模型的分布特征呈现出明显的重心偏移，其高分区间

的峰值显著平缓。这种分布形态的差异暗示，在中性粒细胞这一特定的生理背景下，蛋白的功能依赖性高度集中于少数核心通路。即大部分蛋白对该细胞的即时生存贡献较低，仅有极少数关键节点在复杂的免疫应答网络中维持高水平的权重。

为了准确界定高置信度必需蛋白的边界，进行了阈值敏感性分析。如图 3.1(b) 所示，随着 PES 阈值从 0 逐渐提升至 1.0，两模型筛选出的蛋白数量表现出截然不同的衰减速率。值得注意的是，Immune-level 模型的筛选数量在 PES 从 0.2 提升至 0.6 的中等分值区间内经历了剧烈的下降，这意味着大量具有中等进化保守性的蛋白在免疫背景下的依赖性被显著削弱。随后在 $PES = 0.8$ 附近，曲线的下行斜率明显趋于平稳，进入了高得分的收敛平台区。

在相同的高阈值（$PES = 0.8$）水平下，Human-level 模型保留的蛋白规模远大于 Immune-level 模型，这表明 Immune-level 模型在高分区间施加了更严苛的筛选压力，能够更精准地富集那些在中性粒细胞背景下具有实质性功能贡献的分子。综合分布形态的峰值演变与敏感性曲线的拐点观测，本研究选定 $PES > 0.8$ 作为识别高置信度必需蛋白的阈值。该标准的建立，不仅在统计学上保证了候选集的严谨性，也为后续将蛋白精确划分为人类特异、免疫特异及共同必需三个功能集合提供了定量依据。

图 3.1　Human-level 模型与 Immune-level 模型的 PES 得分对比分析，显示两模型在低分区间具有较高一致性，而在高依赖蛋白区域呈现显著分化。(a) 两模型输出 PES 的散点相关性分布；(b) 不同 PES 阈值下筛选蛋白数量的变化趋势；(c) 两模型在全基因组范围内的 PES 密度分布；(d) 跨模型得分差值 ΔPES 的频率分布；(e) 基于 Bland–Altman 方法的一致性评估。

在确立筛选阈值后，需要通过统计学手段评估双模型预测效能的一致性与差异性。图 3.1(d) 展示两模型得分差值（ΔPES）的频率分布。尽管分布均值 -0.083 略微偏向负值，暗示 PES_{human} 在整体水平上具有略高的得分倾向，但分布曲线呈现出明显的双侧对称长尾结构。这种长尾特征在定量层面证实了前文提及的预测差异：即存在相当比例的蛋白，其必需性评价在不同背景下发生了剧烈波动。这些处于分布末端的离群分子，正是解析中性粒细胞情境依赖性调控机制的关键切入点。

进一步采用更加通用的 Bland–Altman 方法对两模型的一致性进行深度评估，如图 3.1(e) 所示。约 93.2% 的观测点落在 $\pm 1.96SD$ 的一致性区间内，这说明双模型在全基因组水平的预测趋势具备统计学意义的可比性。然而，从散点形态随平均值演变的走势来看，观测点呈现出显著的“漏斗状”扩散态势。

具体而言，在低分区间（$PES \approx 0$），散点紧密围绕均值线分布，说明两模型对非必需蛋白的判定具有极高的共识；而随着平均 PES 值的增大，尤其是进入

0.6 – 1.0 的高依赖区间后，预测差异显著放变大，大量观测点开始逼近甚至突破一致性界限。这种在高分区的差异放大现象并非源于随机误差，而是深刻反映了双模型在处理核心功能蛋白时逻辑维度的本质分歧。在低分区的“一致性”保证了模型的基准可靠性，而高分区的“分歧”则恰恰为锁定中性粒细胞特有的功能节点提供了关键线索。这种分布特征验证了单一模型在处理复杂细胞情境时的局限性，从而支撑了本研究采用双模型联合筛选策略的必要性。

综合上述分析，本研究基于 PES 构建蛋白分群标准，以 $PES > 0.8$ 作为高置信度必需蛋白判定阈值，并在 Human 与 Immune 两个维度上对蛋白进行归类：

- **人类特异必需蛋白**：定义为 $PES_{\text{human}} > 0.8$ 且 $PES_{\text{immune}} \leqslant 0.8$。该类蛋白在种群层面高度受限，反映基础生存需求，构成维持个体生存的基本框架。
- **免疫特异必需蛋白**：定义为 $PES_{\text{immune}} > 0.8$ 且 $PES_{\text{human}} \leqslant 0.8$。该类蛋白在群体层面相对耐受，但在免疫细胞背景下表现出显著依赖性，体现出情境特异的功能需求，具有潜在的靶点开发价值。
- **共同必需蛋白**：定义为 $PES_{\text{human}} > 0.8$ 且 $PES_{\text{immune}} > 0.8$。该类蛋白在两个层级均表现为高依赖，构成生命活动骨架。
- **共同非必需**：定义为 $PES_{\text{human}} \leqslant 0.8$ 且 $PES_{\text{immune}} \leqslant 0.8$。该类蛋白在两个层级中均未表现出显著依赖，由于其在免疫反应中的依赖性较低，本研究未进一步探讨该类蛋白。未来研究可以考虑在特定免疫应答或疾病状态下评估这些蛋白的潜在功能。

通过上述分群策略，本节实现了从模型预测结果到功能集合划分的转化，为后续候选蛋白结构特征分析与功能机制研究奠定基础。

3.2　免疫特异必需蛋白的理化特征分析

中性粒细胞作为高度应激化的先天免疫效应细胞，其功能执行环境具有显著的物理化学压力特征，包括吞噬体快速酸化（pH 4.5–5.0）、ROS 爆发、蛋白酶富集以及高动态膜重塑过程。尤其在急性炎症应答中，活化中性粒细胞表现出氧化爆发增强和颗粒/溶酶体功能负荷升高的状态特征。因此，若免疫特异必需蛋白承担中性粒细胞相关应激功能，其序列层面的理化属性理应呈现与此类环境压力相适应的系统性偏移。为验证该推断，本研究对免疫特异必需蛋白与人类特异必需蛋白在氨基酸组成及整体理化参数层面进行了系统比较分析。

通过图 3.2对氨基酸组成比例的精细化比较发现，免疫特异必需蛋白在残基水平经历了有显著的不同。在碱性氨基酸中赖氨酸（Lys，K）比例显著增加（Δ+3.6%），而同为正电荷残基的精氨酸（Arg，R）增幅相对较小（$\Delta + 1.6\%$）。由于 Lys 侧链

具有更强的构象柔性，且常作为乙酰化、泛素化等关键翻译后修饰的受体，这种非对称性的电荷增加暗示免疫特异必需蛋白在跨膜信号传导与蛋白质降解调控中具有更高的灵活性。与此同时，疏水性残基如缬氨酸（Val，V）的比例有所上升（$\Delta + 0.9\%$），而酸性残基（D, E）及极性不带电残基（N, Q）比例则呈现系统性下降。这种“增疏水、去极性”的趋势有利于在胞内高氧化压力的 ROS 环境下，构建更为致密的内部疏水核心，从而在化学层面减少蛋白主链受氧化损伤的风险。此外，具有高氧化敏感性的半胱氨酸（Cys，C）比例在中性粒细胞特异蛋白中有所降低，这一特征直接降低了蛋白发生非特异性氧化交联的可能性，增强了其在炎症微环境中的结构稳态。

图 3.2　免疫特异必需蛋白与人类特异必需蛋白的氨基酸组成差异比较。该图按残基类别展示两类蛋白在氨基酸组成上的系统偏移，突出免疫特异必需蛋白在碱性残基增加、极性残基减少及疏水性增强等方面的整体趋势。

分析理化属性的统计分布特征进一步印证了上述序列水平的偏移。如图 3.3(a) 所示，免疫特异必需蛋白的分子量显著低于人类特异必需蛋白（$***p < 0.001$）。从分布曲线可以观测到，人类特异蛋白的分子量跨度极大，部分蛋白高达 500 kDa 附近，而免疫特异蛋白的分布则表现出明显的向小分子量偏移，高度集中在 100 kDa 以下的低分子量区间。这种“结构轻量化”趋势在生物学上具有双重意义：一方面，较短的肽链有助于在应急粒生成状态下缩短单分子的翻译耗时，实现免疫效应因子的快速动员；另一方面，小分子量蛋白通常拥有更简单的折叠路径，在极端应激环境下相比大型多畴蛋白更不易发生错误折叠。

图 3.3　不同必需蛋白集合的整体理化性质比较，显示免疫特异必需蛋白整体呈现更轻量、更偏碱性且更具疏水性的理化特征。图中比较的三组分别为免疫特异必需蛋白、人类特异必需蛋白和共同必需蛋白。(a) 蛋白分子量分布；(b) 等电点分布；(c) 净电荷分布；(d) 疏水氨基酸比例分布。箱线图上方标示组间统计显著性。

电荷属性的正向偏移是免疫特异蛋白最显著的统计特征之一。图 3.3(b),(c) 显示，免疫特异必需蛋白 pI 明显升高（$**p = 0.001$），同时净电荷（Net Charge）明显高于人类特异必需蛋白（$***p < 0.001$）。具体而言，其 pI 的分布重心从中性区域向 pI 8.0–10.0 的碱性区间移动。该电荷重分布可能具有多层适应意义：在吞噬体酸化环境中，碱性蛋白更易维持功能所需的电荷状态与构象稳定性；正电表面可增强与带负电分子的静电相互作用，从而提高识别与结合效率；此外，在呼吸爆发过程中，多种蛋白复合体需进行快速、可逆组装，富含碱性残基的表面可能有助于增强瞬时电荷驱动的蛋白–蛋白相互作用。

最后，疏水氨基酸比例表现出统计学意义上的升高 ($*p = 0.041$)。图 3.3(d) 显示，免疫特异蛋白的疏水比例多集中在 45% 至 55% 之间。疏水残基比例的升高通

常意味着蛋白内部折叠核心更加致密稳定。在高 ROS 环境中，强化的疏水核心可减少易氧化位点的暴露面积，提高整体热力学稳定性。同时，中性粒细胞功能涉及大量膜相关与脂质环境过程，适度增强的疏水区域亦可能有助于底物结合或膜界面相互作用。

综合氨基酸组成与整体理化参数的差异，可以观察到免疫特异必需蛋白在多个维度呈现协同偏移：结构轻量化、碱性增强、疏水核心强化以及极性残基减少。这些特征构成一种系统性的理化适应模式，显著契合中性粒细胞所处的酸化、氧化及高酶活性环境，提示免疫特异必需蛋白并非通用必需蛋白的随机子集，而是在特定免疫压力下形成的应激适应型蛋白集合。

3.3　结构域富集与功能机制建模

为系统解析不同必需蛋白亚群在分子层面的功能差异，本研究综合分析了结构域富集、功能关键词富集及亚细胞定位特征。整体趋势如图 3.4、图 3.5 与图 3.6 所示，不同层级的必需蛋白在结构模块构成与功能指向上呈现出系统性分化，提示必需性并非简单来源于表达差异，而是对应于不同的分子功能架构与情境适配策略。

图 3.4　不同必需蛋白亚群的结构域富集比较，揭示三类蛋白在功能模块组成上的系统性差异及潜在分工。(a) 免疫特异必需蛋白中显著富集的代表性结构域；(b) 人类特异必需蛋白中显著富集的代表性结构域；(c) 共同必需蛋白中显著富集的代表性结构域。

图 3.5　不同情境下必需蛋白的功能关键词富集比较，用于刻画不同情境下必需蛋白在应激响应、转录调控及细胞运输等功能上的依赖偏移。(a) 免疫相关依赖情境中显著富集的功能关键词；(b) 人类整体背景中显著富集的功能关键词；(c) 两种情境均显著但富集方向或强度存在差异的共享关键词。

图 3.6　不同必需蛋白亚群的亚细胞定位分布，显示免疫特异必需蛋白相较于人类特异组更偏向线粒体与胞质相关区室，而人类特异必需蛋白则更集中于细胞核。(a) 免疫特异必需蛋白的亚细胞定位比例；(b) 人类特异必需蛋白的亚细胞定位比例；(c) 共同必需蛋白的亚细胞定位比例。

从结构域层面观察，如图 3.4(c) 所示，共同必需蛋白显著集中于 Ig-like C2-type 家族模块。该类结构域广泛参与细胞–细胞识别、膜受体相互作用及信号整合，在维持细胞结构稳定性与跨膜通讯中发挥基础性作用。结合图 3.6(c) 的定位分布可以看出，共同必需蛋白主要位于细胞核及胞质相关区域，提示其构成细胞结构与信号识别网络的基础骨架层。进一步对比图 3.5(c) 可见，即便属于共享功能模块，其在不同情境下的富集强度仍存在方向性偏移，反映出共享通路内部的依赖权重

重分配。

在人类特异必需组中，如图 3.4(b) 所示，Protein kinase、PH、SH2、PDZ 及 Ras-associating 等信号转导相关模块显著富集。相应地，图 3.5(b) 显示其功能关键词主要集中于 chromatin regulator、transcription 与 signal transduction 等类别。从亚细胞定位来看，图 3.6(b) 清晰表明该组蛋白高度偏向细胞核区域。这些证据共同支持，人类特异必需蛋白构成维持个体发育与长期稳态的调控核心层，其必需性主要体现为对转录控制与信号级联节点的依赖。

相比之下，免疫特异必需蛋白呈现出更为显著的应激适配特征。如图 3.4(a) 所示，Mn/Fe SOD N-terminal、BEACH、MHD、bZIP、CBS 及 ENTH 等模块显著富集；图 3.5(a) 进一步显示 autophagy、ubiquitin conjugation 与 mRNA processing 等功能在该组中更为突出。从亚细胞定位角度观察，图 3.6(a) 表明该组蛋白相较于人类特异组在核区域的比例相对降低，而在线粒体及胞质相关区室中的占比有所提高。Mn/Fe SOD N-terminal 结构域的富集提示其可能参与活性氧（ROS）清除与氧化还原稳态维持；结合自噬、膜重塑以及溶酶体相关模块的增强，可以推测该类蛋白更侧重于应激损伤缓冲与细胞器质量控制。基于上述富集趋势，可提出一个情境适配模型：ROS 生成增强 → 颗粒/溶酶体负荷升高 → 抗氧化与修复模块强化 → 自噬与膜运输系统维持损伤清除 → 细胞功能得以稳定。

尤为值得强调的是，共同功能模块在两种情境下呈现出方向性富集偏移。如图 3.5(c) 所示，mRNA processing、microtubule 与 protein transport 在免疫相关依赖情境下富集强度更高，而 repressor 等调控相关功能在人类整体层面偏好更强。这一现象揭示了“共同通路中的差异化依赖”，说明免疫适配并非通过引入全新通路实现，而是在既有基础通路内部重新分配关键步骤的依赖权重，从而实现情境特异的功能重构。

结构域、功能关键词与亚细胞定位的综合分析揭示了三类必需蛋白在功能层级上的系统分化：共同必需蛋白构成细胞结构与识别网络的基础骨架层；人类特异必需蛋白承担基因表达与信号放大的调控核心层；免疫特异必需蛋白则形成氧化还原稳态、自噬适配以及溶酶体负荷缓冲的应激保护层。该结构–功能分层模型为免疫相关依赖特征的分子基础提供了系统性解释，也为后续围绕活化中性粒细胞状态开展靶点筛选与机制验证奠定了理论框架。

通过对三类必需蛋白集合在分子量、电荷分布、结构域构成及亚细胞定位等多维度特征的系统比较，本章识别出一组在种群层面相对耐受、但在免疫细胞应激执行过程中表现出高度依赖性的候选蛋白。这些蛋白所呈现的理化适应模式与中性粒细胞特有的酸化环境及氧化应激状态高度契合，为其潜在功能重要性提供

了结构层面的解释。

基于上述筛选结果，下一章将选取其中具有代表性的候选蛋白，开展结构解析与功能验证，以构建从计算预测到实验验证的完整研究闭环。

3.4　核心候选蛋白的注意力图谱解析与结构域功能验证

在完成对免疫特异必需蛋白的群体理化特征分析后，本小节旨在通过深度学习模型的注意力机制，对最终筛选出的核心候选蛋白进行位点层面的深度解析。通过提取模型在预测 PES_{immune} 评分时的注意力权重分配，可以精确识别出序列中对“免疫必需性”判定贡献最大的关键残基。这种从“整体统计”向“单分子位点”的解析过渡，不仅能够验证模型预测的生物学合理性，更能揭示这些蛋白在中性粒细胞应激环境下的功能执行基础。

本研究选取了筛选结果中具有代表性的核心候选蛋白（如 ATP6V1A、ATP6V1B2、H2BC11 及 PLBD1），通过自注意力热图、归一化重要性曲线、氨基酸理化特征轨以及已知功能结构域四个维度的信息分析这些特征在序列空间上的协同分布，探讨模型判定其为中性粒细胞必需靶点的数理与生物学依据。注意力热图是揭示蛋白内部空间相互作用逻辑与全局关联特征的核心特征，通过热力图的形式展示了序列中任意两个残基之间的关联程度，反映了模型对蛋白质空间折叠与功能协同。归一化重要性曲线通过量化表征序列中每一个氨基酸残基对 PES_{immune} 的边际贡献权重，揭示了蛋白质执行特定免疫功能时的关键位点分布特征，深色覆盖区域代表了该蛋白质中已被科学界确认存在的已知功能域。疏水序列轨定量化地展示蛋白质序列随氨基酸位置变化而产生的“疏水性/亲水性”交替分布的特征轨。这反映了模型对蛋白质空间拓扑结构（如内部核心或膜界面）的深度学习能力。底端的电荷序列轨是揭示蛋白功能微环境的关键维度，通过颜色梯度展示了氨基酸残基在生理 pH（pH 7.0）下的带电状态，绿色代表正电荷，紫色代表负电荷，而白色则代表中性或非极性区域。

1. 吞噬体酸化相关的 V-ATPase 复合体亚基解析　V-ATPase 是维持中性粒细胞吞噬体酸化的重要蛋白复合体，其功能状态直接决定了杀菌微环境的 pH 值稳态。如图 3.7 所示，ATP6V1A（A 亚基）的归一化重要性峰值主要分布于其 V-ATPase A consensus 已知功能域内。模型识别出的关键特征位点包括 W354、M368、F417、Q430 及 W450。

注意力热图（Attention Map）进一步揭示了复杂的残基交互逻辑：核心节点 W354 表现出显著的长程关联性，与序列前端的 K8、S111 以及末端的 S500 存在

强注意力交互。结合底端的理化分布轨可以发现，这些高权重位点在序列空间上展现出显著的理化特征耦合，即重要性峰值多定位于电荷富集区，并与疏水性的局部分布模式高度吻合。

与之对应的 ATP6V1B2 亚基展现了类似的“结构域导向”特征（图 3.8）。其重要性权重高度富集于 V-ATPase B consensus 已知功能域区域。其中 S92 被识别为贡献度最高的特征残基，并与 E70、Q97 及 G173 等位点形成了紧密的自注意力交互网络。其他显著峰值如 T46、F150、S216 和 V317 进一步完善了模型对该亚基必需性的判定依据。这种对 V-ATPase 关键催化亚基的高权重分配，表明模型能够在复杂序列背景下识别与中性粒细胞酸化功能相关的关键区域。

图 3.7　ATP6V1A 的深度注意力机制可视化。图中整合了残基间自注意力热图、归一化重要性曲线及序列理化轨迹，显示模型高权重位点与已知功能域及局部电荷环境具有良好对应关系。

图 3.8　ATP6V1B2 的深度注意力机制可视化。图中展示了关键残基的注意力关联模式、重要性峰值及其对应的疏水性与电荷分布，说明模型对 V-ATPase 功能核心区域具有显著聚焦。

2. 染色质重塑与代谢功能蛋白：H2BC11 与 PLBD1　组蛋白 H2BC11 是中性粒细胞形成 NETs 的关键组分。其注意力图谱（图 3.9）显示，高权重位点高度富集于 Histone H2B 已知核心功能域内。归一化曲线标定了 Y84、S88、H110、S113 及 T120 等关键突刺。

值得注意的是，S113 位点作为关键节点，与 Q96、R100、L107 以及序列末端的 K121、K126 产生了显著的协同贡献（Query-Key 交互点）。理化分布轨显示，这些位点多位于强正电荷区间，这与其在 NETs 形成过程中需要适应中性粒细胞脱颗粒所伴随的离子强度变化、并维持染色质解聚与结构稳态的功能需求相一致。

图 3.9　H2BC11 的深度注意力机制可视化。图中综合展示组蛋白序列内部的注意力热点、残基重要性变化及理化性质分布，突出模型识别出的高权重点与功能域及强带电区段之间的对应关系。

磷脂酶 PLBD1 的分析则揭示了模型对膜相关代谢蛋白的解析逻辑。如图 3.10 所示，其重要性位点分布涵盖了 Phospholipase B-like 已知功能域的多个基序，如 M60、S157、Q314、S368 及 T445。与前述蛋白不同，PLBD1 的注意力权重主要映射在疏水性较强的结构域区间，反映了模型对该蛋白在中性粒细胞溶酶体及膜脂代谢中功能定位的有效识别。关于 PLBD1 在中性粒细胞生理病理过程中的具体作用机制，将在第四章展开详细论述。

图 3.10　PLBD1 的深度注意力机制可视化。图中同时呈现注意力热图、重要性曲线及序列理化轨迹，显示模型关注位点与疏水结构域及潜在功能区域之间具有明确的空间对应。

综合上述典型蛋白的解析结果，可以发现模型提取的重要性位点与本章第二节中统计得出的系统性理化偏移之间逻辑统一：

- **功能域映射的一致性**：归一化重要性峰值与已知功能域的高度重合，证明了模型判定依据的生物学严谨性，即必需性评分源于对核心功能结构域的识别。
- **理化特征的微观验证**：模型在 ATP6V1A 等蛋白中捕捉到的高电荷位点，以及在 PLBD1 中捕捉到的强疏位点，分别在单分子位点层面验证了前文所述的“碱性增强”与“疏水核心强化”等进化适应特征。

综上所述，通过注意力机制解析，本研究不仅从数理层面证实了筛选出的核心候选蛋白在已知功能结构域上的重要性，更明确了一系列关键的功能贡献残基。这些位点不仅是模型判定的数理支撑，也为后续第四章中针对 ATP6V1B2 与 PLBD1 等蛋白开展详细的功能机制探讨奠定了位点层面的研究基础。

第 4 章　核心候选蛋白的机制解析与功能验证

在前述章节中，本研究构建了 Human-level 与 Immune-level 双层蛋白必需性预测模型，并基于 PES 指标建立了跨层级比较框架。通过对 Immune-level 高分蛋白的系统筛选，本研究获得了一批在中性粒细胞相关应激过程中可能具有情境依赖性必需性的候选蛋白。然而，模型预测本身并不等同于生物学事实，其合理性必须通过机制层面的解释与功能对照加以验证。因此，本章围绕预测结果展开机制解析，旨在回答两个核心问题：其一，模型是否识别到了与活化中性粒细胞状态密切相关的分子模块；其二，模型所预测的“情境依赖性必需性”是否能够在既有分子机制层面获得解释与支撑。

4.1　免疫特异性候选蛋白的功能关联分析与筛选结果

中性粒细胞作为先天免疫系统的终末效应细胞，在功能执行过程中处于高度动态的应激环境之中。其吞噬体在形成后迅速酸化，pH 可降至 4.5–5.0；同时伴随 NADPH 氧化酶介导的 ROS 爆发以及大量颗粒融合与膜重塑过程。相关综述指出，中性粒细胞在分化与激活阶段均呈现出显著增强的溶酶体与颗粒系统活性，其蛋白水解与膜周转负荷远高于大多数体细胞[3]。基于此，本文将后续实验所对应的生物学状态具体界定为急性炎症应答中以氧化爆发增强和颗粒/溶酶体功能负荷升高为特征的活化中性粒细胞状态。因此，在此类高负荷环境下维持膜完整性、酸化动力学与蛋白降解效率的分子模块，很可能构成该状态下的关键功能节点。

为进一步验证模型所识别的候选蛋白，本研究对 Immune-level 高分蛋白进行功能注释，发现其功能并非随机分布，而是呈现出明显的聚集趋势。筛选出的免疫特异情景下 PES 前 10 的蛋白如表 4.1 所示，它们在 Immune-level 中的 PES 得分显著高于 Human-level，表明它们在免疫相关应激条件下具有更强的依赖性。这些蛋白在模型中的高评分表明，它们与活化中性粒细胞状态下的核心功能密切相关，尤其集中于酸化、颗粒运输与溶酶体稳态维持等过程。

ATP6V1B2 和 ATP6V1A 的 Immune-level 得分分别为 0.952 和 0.940，显著高于 Human-level 得分，表明它们在免疫相关应激条件下具有较强的功能依赖性。ATP6V1A 和 ATP6V1B2 是 V-ATPase 复合体 V1 结构域的核心亚基，负责 ATP 水解和质子转运。V-ATPase 通过 ATP 水解提供能量，将质子泵入溶酶体等细胞内腔室，维持低 pH 环境，这是溶酶体酸化的关键步骤[70]。

在免疫细胞中，V-ATPase 介导的酸化过程对溶酶体酶的激活和病原清除至关

表 4.1　免疫特异性必需评分前 10 的蛋白

蛋白名称	Human-level PES	Immune-level PES	功能
ATP6V1B2	0.007	0.952	其他功能
ATP6V1A	0.450	0.940	其他功能
PLBD1 (LyLAP)	0.328	0.923	其他功能
H2BC4	0.013	0.891	组蛋白 - 核心组蛋白 H2B
H2BC7	0.013	0.891	组蛋白 - 染色质结构
H2BC11	0.015	0.890	组蛋白 - 核心组蛋白 H2B
H2BC21	0.012	0.888	组蛋白 - 染色质结构
H2BC13	0.012	0.885	组蛋白 - 染色质结构

重要。对于中性粒细胞，V-ATPase 的活性不仅确保酸化过程，还支持吞噬体成熟和与 ROS 的协同作用。因此，V-ATPase 的功能异常会导致免疫反应效率下降，影响病原的清除[71]。

特别是 ATP6V1B2，其在 Immune-level 中的得分为 0.952，而在 Human-level 中仅为 0.007，表现出显著的跨层级差异。这一差异提示 ATP6V1B2 在不同生理环境下可能表现出不同的功能角色。具体来说，在 Human-level 中较低的 PES 值可能反映了其在基础生理条件下的低依赖性，而在 Immune-level 中的高得分则表明，ATP6V1B2 在应激激活状态下的功能需求显著增加。这种跨层级的 PES 差异，可能与活化中性粒细胞在氧化爆发增强和颗粒/溶酶体负荷升高背景下对酸化动力学的特殊需求相关。该状态下，ATP6V1B2 可能通过促进更高效的质子泵装配和质子转运，增强酸性环境的形成，从而促进溶酶体酶的激活和底物降解。

PLBD1（也称为 LyLAP）在免疫激活背景下的高得分（Immune-level PES=0.923）进一步证明了其在中性粒细胞颗粒/溶酶体稳态中的重要角色。与溶酶体膜稳态相关的功能不仅在上述活化状态下具有高依赖性，而且其作用机制也在近年来的研究中得到了详细的证实[72]。

此外，若干组蛋白家族成员（如 H2BC4、H2BC7、H2BC11、H2BC21 和 H2BC13）在 Immune-level 中的高分提示它们可能参与中性粒细胞特有的 NETs 形成过程。NETs 是中性粒细胞在遇到病原体或炎症刺激时，通过一种不同于经典吞噬和脱颗粒的途径，将去凝集的染色质及其相关蛋白质网状释放到胞外形成的防御结构。这种网状结构由 DNA、组蛋白及多种抗菌蛋白（如髓过氧化物酶和弹性蛋白酶）组成，能够物理捕获并杀灭微生物，从而扩展中性粒细胞的杀菌能力[73]。组蛋白不仅是 NETs 结构的核心，还通过后续修饰（如瓜氨酸化）调控 NETs 的形成[74]。在

免疫激活条件下，组蛋白的修饰和去凝集作用尤为重要，反映了它们在中性粒细胞免疫反应中的高必需性。

这些机制性的研究与本研究的 Immune-level 高评分观察高度一致：在静息状态下，这些组蛋白的 Human-level PES 得分较低，但在应激激活条件下显著升高，反映了它们在 NETs 形成这一中性粒细胞特有免疫功能中的增强依赖性。换言之，Immune-level 模型不仅捕捉了这些蛋白的存在，还反映出了它们在特定激活背景下功能权重的动态提升，这与 NETosis 过程中染色质和组蛋白重要性的机制理解相互呼应。

这些结果进一步验证了 Immune-level 模型在识别活化中性粒细胞状态相关必需蛋白方面的准确性和可靠性。

4.2　LyLAP（PLBD1）的机制解析与模型验证意义

PLBD1（Phospholipase B Domain-containing 1）长期以来基于序列同源性注释为类磷脂酶 B 蛋白，但近年来的系统生化实验与结构解析重新界定了其生物学功能。研究证明，该蛋白并非作用于磷脂底物，而是一种 LyLAP[72]。LyLAP 属于 N-末端亲核试剂（Ntn）水解酶家族，其催化活性严格依赖于核心残基 Cys228。图 4.1 展示了 LyLAP 的三维结构，其中橙色区域表示其催化口袋。

图 4.1　LyLAP 三维结构。该图展示了 LyLAP 的整体空间构象及催化口袋在三维结构中的相对位置，其中高亮区域对应催化活性相关的核心表面区域。

成熟与活化依赖溶酶体低 pH 环境，在溶酶体的酸性环境中（pH 4.5），LyLAP 经历自催化切割切除位于 N-末端的抑制性肽段（L209-H227）及组织蛋白酶的协同修饰而趋于成熟，暴露出能够高效结合底物的催化口袋。这种 pH 依赖特性提示其功能与溶酶体环境高度耦合，而非普遍存在于细胞质或中性条件下的蛋白水解系统。

生理底物并非一般可溶性蛋白，而是来源于跨膜蛋白降解过程中残留的疏水 α-螺旋片段。在溶酶体内，跨膜蛋白经多种蛋白酶初步切割后，往往残留较长的疏水跨膜区段。这些肽段由于疏水性强，具有重新插入脂质双层的能力，从而扰乱膜结构稳定性。

通过过程性修剪机制持续切除底物的 N 端氨基酸，逐步缩短疏水链长度，直至其失去嵌入膜结构的能力。选择文献中列举的具有代表性的 LLL-AMC 和 Gly-AMC 两种底物进行对接分析，结果表明，LyLAP 对底物 N 端氨基酸的选择性具有显著差异。图 4.2 展示了切除抑制性肽段后的 LyLAP 与 LLL-AMC 底物的分子对接结果。LLL-AMC 的 N 端富含亮氨酸（Leu），具备强疏水性，与 LyLAP 催化

口袋（CYS-209）形成了强烈的亲和作用，因此 LLL-AMC 与 LyLAP 的结合较为稳固。图 4.3 展示了 LyLAP 与 Gly-AMC 底物的分子对接结果。与 LLL-AMC 相比，Gly-AMC 的 N 端氨基酸为甘氨酸（Gly），其较小且极性的特征使其不如亮氨酸那样能稳定地插入 LyLAP 的疏水性催化口袋，因此 Gly-AMC 表现出较低的亲和力。Gly-AMC 的结合力较弱，表明 LyLAP 对疏水性氨基酸具有更高的亲和力。当 LyLAP 功能缺失时，研究观察到疏水肽段在溶酶体腔内显著积累，并伴随 ESCRT-III 复合体异常招募、溶酶体膜通透性增加以及去酸化现象，最终导致细胞生长受抑与溶酶体功能失衡。

图 4.2　LyLAP 与 LLL-AMC 底物的分子对接结果。图中显示疏水性底物 LLL-AMC 在 LyLAP 催化口袋中的结合构象，提示亮氨酸富集的 N 端基序能够与口袋形成稳定相互作用。

图 4.3　LyLAP 与 Gly-AMC 底物的分子对接结果。图中展示了 Gly-AMC 在催化口袋中的结合姿态，其较弱的疏水嵌合特征与较低亲和倾向相一致。

中性粒细胞含有丰富的颗粒系统，并频繁发生颗粒—溶酶体融合及内吞事件，其跨膜蛋白降解负荷显著高于一般细胞类型。同时，ROS 爆发可能进一步加剧膜结构的不稳定性。在此背景下，疏水跨膜肽段的积累风险明显增加，因此 LyLAP 在中性粒细胞中可能承担更为关键的稳态维持功能。

在 Human-level 模型中的评分相对平缓，而在 Immune-level 模型中显著升高。这种跨层级评分差异与 PIC 框架所提出的“情境依赖性必需性”概念高度一致。因此，LyLAP 的机制解析不仅验证了预测结果的合理性，也为双层模型识别策略提供了机制级支撑。

4.3　ATP6V1B2 的功能推断与验证路径

ATP6V1B2 属于 V-ATPase V1 结构域亚基。研究表明，在应激条件下，ABL1 激酶可磷酸化 ATP6V1B2 的 Y68 位点，促进 V1 结构域与 V0 结构域的装配，从而增强质子转运效率并加速溶酶体酸化[75]。这一调控属于装配动力学调节，而非简单的表达水平变化。

对于中性粒细胞而言，吞噬后酸化的速度直接决定水解酶活化效率与杀菌能力。酸化延迟可能导致蛋白水解效率下降，并削弱 ROS 与水解酶系统的协同作用。因此，ATP6V1B2 在活化中性粒细胞状态中可能成为酸化效率的关键调控节点。

为验证 ATP6V1B2 是否呈现情境依赖性必需性，本研究设计基于 shRNA 的功能干扰实验。考虑到原代中性粒细胞体外存活时间短且遗传操作困难，本文采用 HL-60 作为体外替代模型，并通过 PMA 刺激模拟活化中性粒细胞状态。在此体系

中敲低 ATP6V1B2，并分别在基础条件与 PMA 刺激条件下监测细胞存活率、溶酶体 pH、ROS 水平及水解酶活性。

理论上，若 ATP6V1B2 主要在活化中性粒细胞状态下发挥关键作用，则其敲低对基础条件下细胞的影响应相对有限，而在 PMA 诱导的应激激活条件下则可能导致酸化延迟、酶活下降及生存率显著降低。相关实验数据将在后续研究中补充。

第 5 章　总结与展望

5.1　全文总结

本研究面向中性粒细胞这一终末分化、处于高动态应激状态的免疫细胞，围绕第一章提出的核心问题展开：在原代中性粒细胞高通量功能筛选受限的条件下，如何基于深度学习必需性预测模型识别特定激活状态下的关键功能依赖蛋白。围绕该问题，本文按照“模型预测—候选筛选—机制验证”的总体思路，构建了跨层级蛋白必需性预测框架，并结合结构与功能证据对核心候选蛋白进行了验证。本文在实验层面进一步将关注状态界定为急性炎症应答中以氧化爆发增强和颗粒/溶酶体功能负荷升高为特征的活化中性粒细胞状态。整体而言，本研究在方法、结果与生物学解释三个层面均取得了较为系统的进展。

5.1.1　主要研究工作与结果

第一，构建了面向免疫相关依赖情境的深度学习预测模型。本文采用 ProtT5 预训练蛋白语言模型提取序列嵌入表示，在此基础上构建多种分类头并开展系统消融比较。结果显示，相较于仅依赖池化表示的基线模型，注意力增强结构能够更有效捕捉与必需性判别相关的关键残基信息。在本研究任务设定下，单头注意力结构在性能与稳定性之间取得更优平衡，最终模型在独立测试集上达到 AUROC 0.9272 和 AUPRC 0.8245，说明所构建框架能够在类别不均衡场景中保持较强的识别能力。

第二，建立了 Human-level 与 Immune-level 双层评分体系，并据此解析免疫特异候选蛋白。本文通过构建跨层级 protein essential score（PES）并引入差异指标 ΔPES，对“基础生存重要性”与“免疫相关依赖性”进行区分。基于该框架识别出的高置信候选蛋白并未随机分布，而是在功能与性质层面呈现出清晰聚类。进一步理化特征分析表明，免疫特异候选集合整体体现出正电荷偏移、分子量轻量化与疏水核心强化等趋势，这些变化与活化中性粒细胞在酸性吞噬体环境、强氧化应激与高膜周转负荷下的功能约束方向一致。

第三，围绕核心候选蛋白形成了可解释的机制链条。结合注意力图谱与文献证据，本文重点关注 ATP6V1B2 与 PLBD1（LyLAP）。结果提示，ATP6V1B2 在 Human-level 上得分较低（PES=0.007），而在 Immune-level 上显著升高（PES=0.952），其作用更可能体现为活化中性粒细胞状态下的酸化动力学调控节点，而非一般意义上的基础生存核心因子。对于 PLBD1，本文结果支持其在溶酶体膜稳态维护中

的潜在关键作用，即通过处理疏水肽段降低膜扰动风险。上述发现共同说明，模型不仅能够输出“是否重要”的统计判别，还可为“在何种生理背景下重要”提供机制导向线索。

5.1.2　创新点与研究意义

本研究的贡献可归纳为以下三个方面。

（1）在问题定义层面，本文将蛋白必需性从单一静态标签扩展为跨层级、情境依赖的连续刻画框架。相较于仅报告核心必需与非必需二元分类的传统做法，PES 与 ΔPES 提供了更细粒度的比较维度，有助于区分“基础维持必需”与“免疫功能必需”。

（2）在方法路径层面，本文验证了“序列驱动 + 轻量注意力判别头”在免疫相关依赖预测任务中的可行性。该路径在不依赖昂贵结构实验输入的前提下，仍可实现较高判别性能，为原代免疫细胞中难以直接开展高通量编辑筛选的问题提供了可扩展替代方案。

（3）在应用价值层面，本文筛选得到的候选集合及其机制线索，为后续干预靶点优选提供了依据。尤其是兼具较高 Immune-level 依赖性与较低 Human-level 依赖性的候选蛋白，理论上更具“选择性调控”潜力，可能在降低全身副作用的同时实现对炎症相关过程的有效干预。

5.2　研究局限性分析

尽管本文形成了较完整的计算筛选与机制解释流程，但仍存在以下限制，需要在后续研究中进一步完善。

5.2.1　数据层面的局限

首先，训练标签主要来源于既有大规模筛选数据库与间接映射流程，数据本身受实验体系、细胞背景与统计校正策略影响。即使经过标准化处理，不同来源数据之间仍可能存在不可忽略的批次效应与语境偏差。其次，本研究的 Immune-level 主要反映免疫谱系细胞中的广义依赖特征，尚不能完全覆盖原代中性粒细胞在真实炎症微环境中的状态连续变化。尽管本文在实验验证中进一步聚焦于活化中性粒细胞状态，但当前结果更应理解为“在既定数据语境下具有较高可信度的推断”，其外推范围仍需在更广泛免疫状态中进一步检验。

5.2.2　模型层面的局限

本文以蛋白序列为核心输入，虽具有通用性与可扩展性，但也天然忽略了部分与必需性密切相关的动态信息，包括表达时序变化、翻译后修饰、亚细胞定位动态迁移以及蛋白互作网络重构等。当前模型对这些因素的捕捉主要依赖预训练表示中的隐式编码，尚未实现显式建模。此外，本文采用的判别头结构以性能与可训练稳定性为优先，尚未系统探索更复杂的不确定性估计与因果结构约束，对极端少样本情境的鲁棒性仍有提升空间。

5.2.3　验证层面的局限

本研究的实验支撑主要来自文献一致性、结构解析线索与部分替代体系验证，尚未在原代中性粒细胞中对全部核心候选蛋白开展统一、同尺度的功能扰动实验。考虑到中性粒细胞寿命短、体外维持困难及基因操作窗口受限，当前“计算预测到功能因果”的证据层级仍有提升空间。总体而言，本文已完成从统计关联到机制假设的系统推进；后续若补充更直接的原代扰动实验，可进一步增强结论的因果解释力度与外部效度。

5.3　未来工作展望

围绕上述局限，后续研究可从以下方向展开。

5.3.1　推进多模态信息融合，提升情境分辨率

未来可在现有序列建模框架基础上，引入中性粒细胞不同激活阶段的动态转录组、蛋白质组及空间组学信息，构建显式情境变量约束。通过将细胞状态嵌入与序列表示联合学习，可进一步提高模型对“同一蛋白在不同免疫状态下功能权重变化”的感知能力，从而增强跨条件外推性能。

5.3.2　加强原代细胞验证，补齐因果证据链

在实验策略上，建议优先围绕高 ΔPES 候选建立小规模、高质量验证体系。可结合快速蛋白降解技术（如 PROTAC、dTAG）与时间分辨表型评估，在原代中性粒细胞中直接观察扰动后酸化动力学、膜完整性、吞噬体成熟与 NETs 相关表型变化。该策略有助于将模型输出由“候选排序”进一步推进到“具备因果证据支持的功能节点”。

5.3.3　面向转化应用开展靶点分层与干预设计

对于 ATP6V1B2、PLBD1 等已显示免疫特异依赖倾向的候选蛋白，后续可进一步构建“有效性-安全性”联合评价框架，综合 Human-level 与 Immune-level 评分、组织表达谱、潜在脱靶风险及可成药性指标，形成分层优先级列表。在此基础上推进小分子或生物调控剂开发，有望为慢性炎症、自身免疫相关病理过程及血栓相关疾病提供更具选择性的干预思路。

5.3.4　构建可复用的免疫细胞必需性研究范式

本文提出的跨层级建模与候选筛选流程并不局限于中性粒细胞。未来可迁移至单核/巨噬细胞、T 细胞或组织驻留免疫细胞等体系，形成可复用的免疫细胞必需性研究范式。通过在多细胞类型中的横向验证与对照，进一步识别细胞共性必需模块与细胞特异必需模块，为免疫系统层面的精细化靶点发现提供方法基础。

综上，本文在中性粒细胞情境下完成了从模型构建到候选机制解析的初步研究流程，证明了序列驱动深度学习在免疫特异必需蛋白发现中的可行性。随着多模态数据融合与原代验证体系的持续推进，该研究路线有望进一步提升在机制阐释与临床转化中的应用价值。

参考文献

[1] Maier-Begandt D, Zarbock A, Ludwig S. Neutrophils—biology and diversity[J]. Nephrology Dialysis Transplantation, 2024, 39(10): 1551-1564.

[2] Mayadas T N, Cullere X, Lowell C A. The multifaceted functions of neutrophils[J]. Nature Reviews Immunology, 2014, 14(5): 259-273.

[3] Aroca-Crevillén A, Vicanolo T, Ovadia S, et al. Neutrophils in physiology and pathology[J]. Annual Review of Pathology: Mechanisms of Disease, 2024, 19: 227-259.

[4] Rosales C. Neutrophil: a cell with many roles in inflammation or several cell types?[J]. Frontiers in Physiology, 2018, 9: 113.

[5] Baaten C C, Nagy M, Spronk H M, et al. Netosis in cardiovascular disease: An opportunity for personalized antithrombotic treatments?[J]. Arteriosclerosis, Thrombosis, and Vascular Biology, 2024, 44(12): 2366-2370.

[6] Zhang X, Acencio M L, Lemke N. Predicting essential genes and proteins based on machine learning and network topological features: A comprehensive review[J]. Frontiers in Physiology, 2016, 7: 75.

[7] Xiao Q, Wang J, Peng X, et al. Identifying essential proteins from active ppi networks constructed with dynamic gene expression[J]. BMC Genomics, 2015, 16(Suppl 3): S1.

[8] Jeong H, Mason S P, Barabási A L, et al. Lethality and centrality in protein networks[J]. Nature, 2001, 411: 41-42.

[9] Shalem O, Sanjana N E, Hartenian E, et al. Genome-scale crispr-cas9 knockout screening in human cells[J]. Science, 2014, 343(6166): 84-87.

[10] Li W, Xu H, Xiao T, et al. Mageck enables robust identification of essential genes from genome-scale crispr/cas9 knockout screens[J]. Genome Biology, 2014, 15: 554.

[11] Meyers R M, Bryan J G, McFarland J M, et al. Computational correction of copy number effect improves specificity of crispr-cas9 essentiality screens in cancer cells[J]. Nature Genetics, 2017, 49(12): 1779-1784.

[12] Tsherniak A, Vazquez F, Montgomery P G, et al. Defining a cancer dependency map[J]. Cell, 2017, 170(3): 564-576.e16.

[13] Hart T, Chandrashekhar M, Aregger M, et al. High-resolution crispr screens reveal fitness genes and genotype-specific cancer liabilities[J]. Cell, 2015, 163(6): 1515-1526.

[14] Blomen V A, Májek P, Jae L T, et al. Gene essentiality and synthetic lethality in haploid human cells[J]. Science, 2015, 350: 1092-1096.

[15] Wang T, Wei J J, Sabatini D M, et al. Identification and characterization of essential genes in the human genome[J]. Science, 2015, 350: 1096-1101.

[16] Birsoy K, Possemato R, Lorbeer F K, et al. Metabolic determinants of cancer cell sensitivity to glucose limitation and biguanides[J]. Nature, 2014, 508(7494): 108-112.

[17] Replogle J M, Saunders R A, Pogson A N, et al. Mapping information-rich genotype-phenotype landscapes with genome-scale perturb-seq[J]. Cell, 2022, 185(14): 2559-2575.e28.

[18] Zhou P, Shi H, Huang H, et al. Single-cell crispr screens in vivo map t cell fate regulomes in cancer[J]. Nature, 2023, 624(7990): 154-163.

[19] Xie X, Shi Q, Wu P, et al. Single-cell transcriptome profiling reveals neutrophil heterogeneity in homeostasis and infection[J]. Nature Immunology, 2020, 21(9): 1119-1133.

[20] Rives A, Meier J, Sercu T, et al. Biological structure and function emerge from scaling unsupervised learning to 250 million protein sequences[J]. Proceedings of the National Academy of Sciences, 2021, 118(15): e2016239118.

[21] Lin Z, Akin H, Rao R, et al. Evolutionary-scale prediction of atomic-level protein structure with a language model[J]. Science, 2023, 379(6637): 1123-1130.

[22] Giaever G, Chu A M, Ni L, et al. Functional profiling of the saccharomyces cerevisiae genome [J]. Nature, 2002, 418(6896): 387-391.

[23] Hutchison I, Clyde A., Peterson S N, Gill S R, et al. Global transposon mutagenesis and a minimal mycoplasma genome[J]. Science, 1999, 286(5447): 2165-2169.

[24] Hutchison C A I, Chuang R Y, Noskov V N, et al. Design and synthesis of a minimal bacterial genome[J]. Science, 2016, 351(6280): aad6253.

[25] Mohr S E, Smith J A, Shamu C E, et al. Rnai screening comes of age: improved techniques and complementary approaches[J]. Nature Reviews Molecular Cell Biology, 2014, 15(9): 591-600.

[26] Jackson A L, Linsley P S. Recognizing and avoiding sirna off-target effects for target identification and therapeutic application[J]. Nature Reviews Drug Discovery, 2010, 9(1): 57-67.

[27] Echeverri C J, Beachy P A, Baum B, et al. Minimizing the risk of reporting false positives in large-scale rnai screens[J]. Nature Methods, 2006, 3(10): 777-779.

[28] Birmingham A, Anderson E M, Reynolds A, et al. 3' utr seed matches, but not overall identity, are associated with rnai off-targets[J]. Nature Methods, 2006, 3(3): 199-204.

[29] Doench J G, Fusi N, Sullender M E, et al. Optimized sgrna design to maximize activity and minimize off-target effects of crispr-cas9[J]. Nature Biotechnology, 2016, 34(2): 184-191.

[30] Behan F M, Iorio F, Picco G, et al. Prioritization of cancer therapeutic targets using crispr-cas9 screens[J]. Nature, 2019, 568(7753): 511-516.

[31] Hart T, Moffat J. Bagel: a computational framework for identifying essential genes from pooled library screens[J]. BMC Bioinformatics, 2016, 17: 164.

[32] Shifrut E, Carnevale J, Tobin V, et al. Genome-wide crispr screens in primary human t cells reveal key regulators of immune function[J]. Cell, 2018, 175(7): 1958-1971.e15.

[33] Nasri M, Ritter M, Mir P, et al. Crispr/cas9-mediated elane knockout enables neutrophilic maturation of primary hematopoietic stem and progenitor cells and induced pluripotent stem cells of severe congenital neutropenia patients[J]. Haematologica, 2020, 105(3): 598-609.

[34] Allen J, Rorvig S, Wölfel F, et al. Closing the gap between murine neutrophils and neutrophil-like cell lines[J]. Journal of Leukocyte Biology, 2023, 114(3): 199-212.

[35] Hahn M W, Kern A D. Comparative genomics of centrality and essentiality in three eukaryotic protein-interaction networks[J]. Molecular Biology and Evolution, 2005, 22(4): 803-806.

[36] He X, Zhang J. Why do hubs tend to be essential in protein networks?[J]. PLoS Genetics, 2006, 2(6): e88.

[37] Yu H, Greenbaum D, Lu H, et al. Genomic analysis of essentiality within protein networks[J]. Trends in Genetics, 2008, 24(5): 227-231.

[38] Han J D J, Bertin N, Hao T, et al. Evidence for dynamically organized modularity in the yeast protein-protein interaction network[J]. Nature, 2004, 430(6995): 88-93.

[39] Luck K, Kim D K, Lambourne L, et al. A reference map of the human binary protein interactome [J]. Nature, 2020, 580(7803): 402-408.

[40] Deng J, Deng L, Su S, et al. Investigating the predictability of essential genes across distantly related organisms using an integrative approach[J]. Nucleic Acids Research, 2011, 39(3): 795-807.

[41] Anaissi A, Kennedy P J, Goyal M. A balanced iterative random forest for gene selection from microarray data[J]. BMC Bioinformatics, 2013, 14: 261.

[42] Nigatu D, Sobetzko P, Yousef M, et al. Sequence-based information-theoretic features for gene essentiality prediction[J]. BMC Bioinformatics, 2017, 18(1): 473.

[43] Zhang X, Xu J, Xiao W. Detecting essential proteins based on network topology, gene expression data, and gene ontology information[J]. IEEE/ACM Transactions on Computational Biology and Bioinformatics, 2018, 15(3): 1093-1100.

[44] Wang S, Peng J, Ma J, et al. Protein secondary structure prediction using deep convolutional neural fields[J]. Scientific Reports, 2016, 6: 18962.

[45] Wang D, Zeng S, Xu C, et al. Musitedeep: a deep-learning framework for general and kinase-specific phosphorylation site prediction[J]. Bioinformatics, 2017, 33(24): 3909-3916.

[46] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.

[47] van Opijnen T, Camilli A. Transposon insertion sequencing: a new tool for systems-level analysis of microorganisms[J]. Nature Reviews Microbiology, 2013, 11: 435-442.

[48] Zhang R, Ou H Y, Zhang C T. Deg: a database of essential genes[J]. Nucleic Acids Research, 2004, 32(D1): D271-D272.

[49] Gilmer J, Schoenholz S S, Riley P F, et al. Neural message passing for quantum chemistry[C]// International Conference on Machine Learning. 2017.

[50] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[C]// International Conference on Learning Representations. 2017.

[51] wwPDB consortium. Protein data bank: the single global archive for 3d macromolecular structure data[J]. Nucleic Acids Research, 2019, 47(D1): D520-D528.

[52] Heinzinger M, Elnaggar A, Wang Y, et al. Modeling aspects of the language of life through transfer-learning protein sequences[J]. Bioinformatics, 2019, 35(14): i321-i329.

[53] Bepler T, Berger B. Learning protein sequence embeddings using information from structure [C]//International Conference on Learning Representations (ICLR). 2019.

[54] Alley E C, Khimulya G, Biswas S, et al. Unified rational protein engineering with sequence-based deep representation learning[J]. Nature Methods, 2019, 16(12): 1315-1322.

[55] Rao R, Bhattacharya N, Thomas N, et al. Evaluating protein transfer learning with tape[C]// Advances in Neural Information Processing Systems (NeurIPS). 2019.

[56] Rao R, Meier J, Sercu T, et al. Transformer protein language models are unsupervised structure learners[C]//International Conference on Learning Representations (ICLR). 2021.

[57] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017.

[58] Jumper J, Evans R, Pritzel A, et al. Highly accurate protein structure prediction with alphafold [J]. Nature, 2021, 596: 583-589.

[59] Elnaggar A, Heinzinger M, Dallago C, et al. Prottrans: Toward understanding the language of life through self-supervised learning[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(10): 7112-7127.

[60] Meier J, Rao R, Verkuil R, et al. Language models enable zero-shot prediction of the effects of mutations on protein function[C]//Advances in Neural Information Processing Systems (NeurIPS). 2021.

[61] Brandes N, Ofer D, Peleg Y, et al. Proteinbert: a universal deep-learning model of protein sequence and function[J]. Bioinformatics, 2022, 38(8): 2102-2110.

[62] Kang B, Fan R, Cui C, et al. Comprehensive prediction and analysis of human protein essentiality based on a pretrained large language model[J]. Nature Computational Science, 2024, 4: 1-14.

[63] Karczewski K J, Francioli L C, Tiao G, et al. The mutational constraint spectrum quantified from variation in 141,456 humans[J]. Nature, 2020, 581(7809): 434-443.

[64] Lek M, Karczewski K J, Minikel E V, et al. Analysis of protein-coding genetic variation in 60,706 humans[J]. Nature, 2016, 536(7616): 285-291.

[65] UniProt Consortium. Uniprot: the universal protein knowledgebase in 2023[J]. Nucleic Acids Research, 2023, 51(D1): D523-D531.

[66] ALIPANAHI B, DELONG A, WEIRAUCH M T, et al. Predicting the sequence specificities of dna- and rna-binding proteins by deep learning[J]. Nature Biotechnology, 2015, 33(8): 831-838.

[67] Kulmanov M, Hoehndorf R. Deepgoplus: improved protein function prediction from sequence [J]. Bioinformatics, 2020, 36: 422-429.

[68] Dill K A, MacCallum J L. The protein-folding problem, 50 years on[J]. Science, 2012, 338 (6110): 1042-1046.

[69] Vogel C, Chothia C. Protein family expansions and biological complexity[J]. PLoS Computational Biology, 2006, 2(5): e48.

[70] Chen Y Y, Liu C X, Liu H X, et al. The emerging roles of vacuolar-type atpase-dependent lysosomal acidification in cardiovascular disease[J]. Biomolecules, 2025, 15(4): 525.

[71] Kim S H, Cho Y S, Jung Y K. Failure of lysosomal acidification and endomembrane network in neurodegeneration[J]. Experimental & Molecular Medicine, 2025, 57: 2418-2428.

[72] Jain A, Heremans I, Rademaker G, et al. Leucine aminopeptidase LyLAP enables lysosomal degradation of membrane proteins[J]. Science, 2025, 387(6741): adq8331.

[73] Shahzad A, Ni Y, Yang Y, et al. Neutrophil extracellular traps (nets) in health and disease[J]. Molecular Biomedicine, 2025, 6(1): 130.

[74] Hamam H J, Khan M A, Palaniyar N. Histone acetylation promotes neutrophil extracellular trap formation[J]. Biomolecules, 2019, 9(1): 32.

[75] Song C, Dong Q, Yao Y, et al. Nonreceptor tyrosine kinase ABL1 regulates lysosomal acidification by phosphorylating the ATP6V1B2 subunit of the vacuolar-type H^+-atpase[J]. Autophagy, 2025, 21(6): 1192-1211.

致　谢

衷心感谢导师 ××× 教授和物理系 ×× 副教授对本人的精心指导。他们的言传身教将使我终生受益。

在美国麻省理工学院化学系进行九个月的合作研究期间，承蒙 Robert Field 教授热心指导与帮助，不胜感激。

感谢 ××××× 实验室主任 ××× 教授，以及实验室全体老师和同窗们学的热情帮助和支持！

本课题承蒙国家自然科学基金资助，特此致谢。

声　明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果，不包含涉及国家秘密的内容。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签　名：_____日　期：_____

个人简历、在学期间完成的相关学术成果

个人简历

197× 年 ×× 月 ×× 日出生于四川 ×× 县。

1992 年 9 月考入 ×× 大学化学系 ×× 化学专业，1996 年 7 月本科毕业并获得理学学士学位。

1996 年 9 月免试进入清华大学化学系攻读 ×× 化学博士至今。

在学期间完成的相关学术成果

学术论文：

[1] Yang Y, Ren T L, Zhang L T, et al. Miniature microphone with silicon-based ferroelectric thin films[J]. Integrated Ferroelectrics, 2003, 52:229-235.

[2] 杨轶, 张宁欣, 任天令, 等. 硅基铁电微声学器件中薄膜残余应力的研究 [J]. 中国机械工程, 2005, 16(14):1289-1291.

[3] 杨轶, 张宁欣, 任天令, 等. 集成铁电器件中的关键工艺研究 [J]. 仪器仪表学报, 2003, 24(S4):192-193.

[4] Yang Y, Ren T L, Zhu Y P, et al. PMUTs for handwriting recognition. In press[J]. (已被 Integrated Ferroelectrics 录用)

专利：

[5] 任天令, 杨轶, 朱一平, 等. 硅基铁电微声学传感器畴极化区域控制和电极连接的方法: 中国, CN1602118A[P]. 2005-03-30.

[6] Ren T L, Yang Y, Zhu Y P, et al. Piezoelectric micro acoustic sensor based on ferroelectric materials: USA, No.11/215, 102[P]. (美国发明专利申请号.)

指导教师评语

论文提出了……

答辩委员会决议书

论文提出了……

论文取得的主要创新性成果包括：

1. ……

2. ……

3. ……

论文工作表明作者在 ××××× 具有 ××××× 知识，具有 ×××× 能力，论文 ××××，答辩 ××××。

答辩委员会表决，（× 票/一致）同意通过论文答辩，并建议授予 ×××（姓名）×××（门类）学博士/硕士学位。